



上海交通大学

SHANGHAI JIAO TONG UNIVERSITY

XXXX 课程报告

XXXXXX 进展调研

学院 电子信息与电气工程学院

班级 电院 23DXXX

学号 023XXXXXXX

姓名 XXX

2025 年 12 月 28 日

目录

1 引言：并行计算基础	5
1.1 并行计算概述	5
1.1.1 并行计算的分类	5
1.2 OpenMP 并行编程模型	5
1.3 性能评估指标	6
1.3.1 加速比 (Speedup)	6
1.3.2 并行效率 (Efficiency)	6
1.3.3 Amdahl 定律	6
1.4 Roofline 模型	7
1.5 性能 benchmark 与测试环境	7
2 神经网络算子并行化	9
2.1 计算密集型 vs 访存密集型	9
2.1.1 计算密集型 (Compute-Bound)	9
2.1.2 访存密集型 (Memory-Bound)	9
2.2 卷积算子 (Conv2d) - 计算密集型	10
2.2.1 算法原理	10
2.2.2 实现策略演进	10
2.2.3 并行化挑战与优化	11
2.3 平均池化算子 (AvgPool2d) - 访存密集型	12
2.3.1 算法原理	12
2.3.2 并行实现与性能	12
2.4 小结	13
3 红黑排序 Gauss-Seidel 迭代法	14
3.1 算法原理	14
3.2 红黑排序 (Red-Black Ordering)	14
3.3 OpenMP 并行化与 Barrier 同步机制	15
3.3.1 Barrier 同步原理	15
3.3.2 红黑 GS 中的 Barrier 需求	15
3.4 小规模问题的并行困境	15
3.4.1 为什么小规模问题“越并行越慢”？	15
3.4.2 规模阈值分析	16
3.5 两种优化方法	17
3.5.1 Original 方法：基础红黑排序并行	17
3.5.2 Tiled 方法：多级缓存分块优化	17

3.6 性能测试结果	18
3.7 小结	18
4 三对角方程组并行求解	20
4.1 问题定义	20
4.2 Thomas 算法（串行基准）	20
4.3 Brugnano 并行算法 - 区域分解法	21
4.3.1 算法原理	21
4.3.2 实现关键技术	21
4.4 递归倍增 (Recursive Doubling) 算法	21
4.4.1 算法原理	21
4.4.2 算法特点	22
4.5 并行化难点分析	22
4.5.1 难点 1: 串行依赖链	22
4.5.2 难点 2: 规模阈值效应	22
4.5.3 难点 3: 算法本身开销	23
4.6 性能测试结果	23
4.7 小结	24
5 并行算法性能总结与展望	25
5.1 并行性能规律总结	25
5.1.1 规模效应的普遍性	25
5.1.2 同步开销的主导作用	25
5.1.3 内存带宽限制	26
5.1.4 线程扩展性的衰减规律	26
5.2 关键发现与洞察	26
5.2.1 并行不是万能药	26
5.2.2 算法复杂度决定并行价值	27
5.2.3 内存访问模式的重要性	27
5.3 局限性与未来工作	28
5.3.1 本研究的局限性	28
5.3.2 未来研究方向	28
5.4 全文总结	29
A 详细性能测试数据	30
A.1 神经网络算子性能数据	30
A.1.1 卷积算子并行位置对比	30
A.1.2 平均池化算子访存优化效果	32

A.2	Gauss-Seidel 迭代法完整数据	33
A.2.1	2D 红黑 Gauss-Seidel 性能数据 (1000 次迭代)	33
A.2.2	3D 红黑 Gauss-Seidel 性能数据 (100 次迭代)	36
A.3	三对角方程组求解完整数据	38
B	关键代码实现	43
B.1	神经网络算子实现	43
B.2	Padding 实现	43
B.2.1	卷积空间并行实现	43
B.2.2	平均池化并行实现	47
B.3	Gauss-Seidel 迭代法实现	49
B.3.1	2D 红黑排序实现	49
B.3.2	3D 红黑排序实现	52
B.4	三对角方程组求解实现	55
B.4.1	Sequential Thomas 算法	55
B.4.2	Brugnano 并行算法	55
B.4.3	Recursive Doubling 算法	58
C	写在最后	60
C.1	发布地址	60

1 引言：并行计算基础

1.1 并行计算概述

并行计算是指同时使用多个计算资源解决计算问题的过程。随着处理器主频增长放缓，多核处理器成为提升计算性能的主要途径。通过将任务分解为可以并发执行的子任务，并行计算能够显著缩短程序运行时间，提高计算效率。

1.1.1 并行计算的分类

根据并行粒度的不同，**并行计算可分为：**

- **任务级并行 (Task-Level Parallelism):** 将不同的任务分配给不同的处理器执行
- **数据级并行 (Data-Level Parallelism):** 对大规模数据集的不同部分同时进行相同操作
- **指令级并行 (Instruction-Level Parallelism):** 在单个处理器内同时执行多条指令

本项目主要关注数据级并行，利用 OpenMP 实现共享内存多线程并行。

1.2 OpenMP 并行编程模型

OpenMP (Open Multi-Processing) 是一种支持共享内存并行编程的 API，广泛应用于 C/C++ 和 Fortran 程序中。其主要特点包括：

- **Fork-Join 模型：**主线程创建多个工作线程，并行执行后再汇合
- **编译器指令：**通过 `#pragma omp` 指令控制并行行为
- **可移植性强：**支持多种编译器和操作系统
- **增量并行化：**可逐步对串行程序进行并行优化

常用的 OpenMP 并行指令包括：

- `#pragma omp parallel for`: 并行执行 for 循环
- `#pragma omp parallel sections`: 并行执行不同的代码段
- `#pragma omp critical`: 保护临界区
- `#pragma omp barrier`: 设置同步点

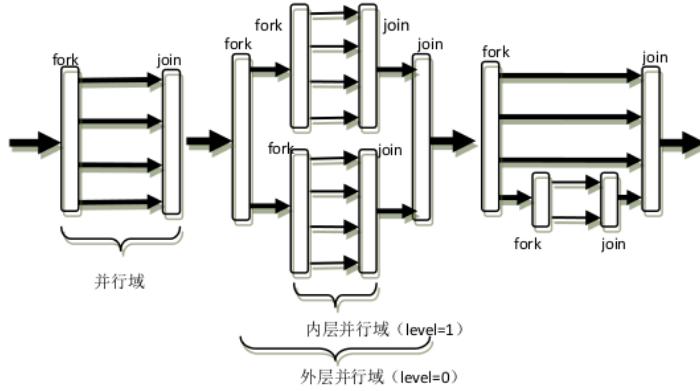


图 1: OpenMP Fork-Join 模型示意图

1.3 性能评估指标

1.3.1 加速比 (Speedup)

加速比是衡量并行性能最常用的指标，定义为：

$$S_p = \frac{T_1}{T_p} \quad (1)$$

其中 T_1 为串行执行时间, T_p 为使用 p 个处理器的并行执行时间。理想情况下 $S_p = p$ (线性加速)，但实际中通常 $S_p < p$ 。

1.3.2 并行效率 (Efficiency)

并行效率衡量处理器资源的利用率：

$$E_p = \frac{S_p}{p} = \frac{T_1}{p \cdot T_p} \quad (2)$$

理想情况下 $E_p = 1$ (100%)，表示所有处理器都被充分利用。

1.3.3 Amdahl 定律

Amdahl 定律描述了程序中串行部分对并行加速比的限制：

$$S_p \leq \frac{1}{f + \frac{1-f}{p}} \quad (3)$$

其中 f 是程序中不可并行部分的比例。当 $p \rightarrow \infty$ 时， $S_p \rightarrow \frac{1}{f}$ 。这说明即使有无限多处理器，加速比也受串行部分的限制。

1.4 Roofline 模型

Roofline 模型是分析程序性能的重要工具，它描述了性能上限由两个因素决定：

$$\text{Performance} = \min(\text{Peak FLOPS}, \text{Arithmetic Intensity} \times \text{Memory Bandwidth}) \quad (4)$$

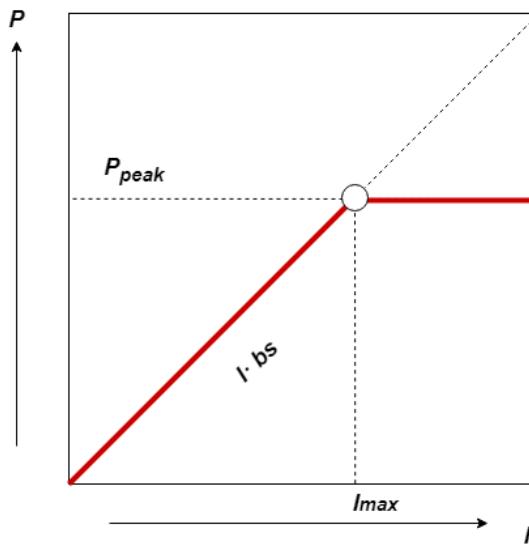


图 2: Roofline 模型示意图

图中的 I_{max} 为拐点所对应的强度，是计算平台的计算强度上限。当 $I < I_{max}$ 时，模型的计算性能受限于带宽大小，处于带宽瓶颈区；当 $I > I_{max}$ 时，模型的计算性能瓶颈取决于平台的算力，处于计算瓶颈区。所以，模型的计算强度应尽量大于 I_{max} ，这样才能最大程度利用计算平台的算力资源，但超过之后就无需追求无意义的提升，因为再强性能都只能达到计算平台的算力。

1.5 性能 benchmark 与测试环境

本项目的所有性能测试均在以下环境下进行：

- 处理器：AMD Ryzen AI 9 H 365 w/ Radeon 880M (10 核心 20 线程，基频 2.0GHz)
- 内存：32GB
- 编译器：GCC 15.2.0 (MinGW)，Clang 17.0.6
- 操作系统：Windows 11 家庭中文版
- 并行库：OpenMP

性能测试方法：

- 测试算子时先 50 次 warm up，再 200 次取中位数和 P99
- 使用高精度计时器 (`std::chrono::high_resolution_clock`)
- 测试前进行 warm-up 避免冷启动影响

2 神经网络算子并行化

神经网络中的算子计算通常具有高度的数据并行性，通过 OpenMP 等并行技术可以显著提升计算性能。本节介绍两个典型的神经网络算子：卷积（Convolution）和平均池化（Average Pooling）的并行实现。

2.1 计算密集型 vs 访存密集型

在并行计算中，算子的性能特征可以分为两类：

2.1.1 计算密集型（Compute-Bound）

计算密集型任务的核心定义是算法的性能瓶颈在于计算单元（如 ALU、FPU）的吞吐量，而非内存带宽。这类任务具有高计算访存比，即每次内存访问都会对应大量计算操作，算术强度显著偏高，浮点运算次数与内存访问字节数的比值远大于 1，其性能瓶颈主要集中在处理器的浮点运算能力，因此在并行处理场景中通常能获得较好的加速比。

计算密集型任务的典型例子包括卷积操作和矩阵乘法，其中卷积操作以输入 (1, 3, 150, 150)、输出 (1, 32, 150, 150)、步长 stride=1、填充 padding=2、卷积核大小 kernel_size=(5, 5) 为例，算术强度约为 386.27 FLOP/byte；而矩阵乘法对于 $n \times n$ 规模的矩阵，算术强度约为 $\frac{n}{3}$ FLOP/byte，且随着 n 的增大，算术强度的特征会更加显著。针对计算密集型任务的优化策略主要包括增加并行度，比如通过多线程、SIMD 技术提升并行处理能力，同时可通过提高指令级并行、循环展开等方式进一步挖掘性能潜力。

计算密集型任务的并行加速比接近线性，其主要挑战在于实现负载均衡，避免部分计算单元处于空闲状态，优化重点始终围绕增加计算并行度展开，性能特征上则接近处理器的峰值浮点运算性能（Peak FLOPS），对应性能屋顶模型中的水平部分。

2.1.2 访存密集型（Memory-Bound）

访存密集型任务与计算密集型任务形成鲜明对比，其性能瓶颈在于内存系统的带宽，而非处理器的计算能力。这类任务的计算访存比偏低，每次内存访问仅对应少量计算操作，算术强度较小，浮点运算次数与内存访问字节数的比值远小于 1，性能表现主要受限于内存带宽大小和缓存命中率高低，在并行处理场景中，由于内存带宽的限制，加速比提升空间会受到明显约束。

访存密集型任务的典型例子包括池化操作、Batch Normalization 以及 ReLU 等激活函数，其中 2×2 规模的池化操作算术强度约为 0.31 FLOP/byte，Batch Normalization 操作主要以内存读写为主，仅伴随少量简单运算，而 ReLU 等激活函数多为逐元素操作，计算量极小，核心开销集中在内存访问过程中。针对这类任务的优化策略需围绕内存访问效率展开，比如通过数据重用、分块处理等方式提高缓存命中率，减少不必要的

内存访问次数，同时可通过预取优化、调整内存访问模式等手段进一步降低内存访问延迟、提升内存带宽利用率。

访存密集型任务的并行加速比明显受限，核心挑战在于多线程并行时的内存带宽竞争，多个线程同时访问内存会导致带宽资源紧张，反而可能出现性能下降的情况，因此优化重点在于减少内存访问总量、提高缓存利用效率。其性能特征严格受限于内存带宽，无法充分发挥处理器的计算能力，对应性能屋顶模型中的斜线部分，即性能随内存带宽的提升而增长，却难以突破内存带宽带来的上限约束。

2.2 卷积算子 (Conv2d) - 计算密集型

2.2.1 算法原理

二维卷积是深度学习中最基础且最重要的操作之一。给定输入特征图 $X \in \mathbb{R}^{C_{in} \times H_{in} \times W_{in}}$ 和卷积核 $W \in \mathbb{R}^{C_{out} \times C_{in} \times K_h \times K_w}$ ，卷积操作计算输出特征图 $Y \in \mathbb{R}^{C_{out} \times H_{out} \times W_{out}}$ ：

$$Y[o, h, w] = b[o] + \sum_{c=0}^{C_{in}-1} \sum_{i=0}^{K_h-1} \sum_{j=0}^{K_w-1} X[c, h \cdot s_h + i, w \cdot s_w + j] \cdot W[o, c, i, j] \quad (5)$$

其中 C_{in}, C_{out} 为输入和输出通道数， K_h, K_w 为卷积核高度和宽度， s_h, s_w 为步长， $b[o]$ 为偏置项。输出特征图的尺寸计算公式：

$$H_{out} = \left\lfloor \frac{H_{in} + 2 \cdot \text{padding} - K_h}{s_h} \right\rfloor + 1 \quad (6)$$

2.2.2 实现策略演进

本项目实现了三个版本的卷积算子，展示了从串行到并行、再到深度优化的演进过程。

版本 1：串行实现 - 使用动态计数器记录输出位置，逻辑简单但存在数据依赖，无法直接并行。

[Code Listing 2](#)展示了该版本的核心代码。

问题分析： `cnt[c]++` 操作存在数据竞争而无法直接并行化，`weight_pos` 采用循环累加的实现方式导致存在跨线程依赖，同时索引计算逻辑复杂也显著降低了执行性能。

版本 2：并行实现 - 改为静态索引计算，在输出通道维度并行，消除依赖但并行粒度仅 32。

[Code Listing 3](#)展示了该版本的核心代码。

问题分析： 索引计算逻辑仍较为复杂，导致计算开销偏高；相同索引被多次重复计算，进一步增加了性能损耗；此外，代码还可能存在伪共享（False Sharing）问题，影响并行执行效率。

版本 3：深度优化实现 - 针对版本 2 的瓶颈实现三方面优化：

[Code Listing 4](#)展示了该版本的核心代码。

如[表 1](#)所示，三个版本的性能对比清晰展现了优化效果。

表 1: 普通并行 vs 优化后并行性能对比

线程数	普通并行			优化后并行			性能提升率 (vs 普通并行)
	中位数时间 (ms)	加速比	效率 (%)	中位数时间 (ms)	加速比	效率 (%)	
1	18.20	1.00	100.00	18.58	1.00	100.00	-2.1%
2	9.88	1.84	91.90	9.32	1.99	99.50	+5.7%
4	5.52	3.30	82.54	4.93	3.77	94.25	+10.7%
8	4.01	4.54	56.72	3.72	5.00	62.50	+7.2%
10	4.05	4.49	44.91	2.82	6.59	65.90	+30.4%
16	3.63	5.01	31.32	2.65	7.00	43.75	+27.0%
20	3.54	5.14	25.68	2.36	7.86	39.30	+33.3%

2.2.3 并行化挑战与优化

1. 并行粒度选择 - 如[表 2](#)所示，不同并行维度性能差异巨大。

表 2: 卷积不同并行粒度的性能对比

并行维度	并行数	每线程计算量	开销占比	推荐度
width(w)	150	~600 FLOP	>99%	极差
height(h)	150	~90K FLOP	~10%	较差
输入通道 (ic)	3	~16M FLOP	<0.1%	一般
输出通道 (oc)	32	~1.7M FLOP	<1%	最佳

关键发现：width 并行灾难性失败（20 线程反而慢 69×），原因是线程开销远大于计算时间；输出通道并行表现最佳；二维空间并行进一步优化（加速 7.86×）。

2. False Sharing - 解决方案：按输出通道并行或二维空间并行，每线程写入独立位置。

3. 内存带宽限制 - 算术强度约 386.27 FLOP/byte，虽属计算密集型，但多线程时仍可能受带宽限制。这是由于本次测试用的张量维数较低，计算量不够大，对于现代 CPU 来说，瓶颈仍为内存访问。

2.3 平均池化算子 (AvgPool2d) - 访存密集型

2.3.1 算法原理

平均池化对输入特征图的局部区域求平均，用于降采样。给定输入 $X \in \mathbb{R}^{C \times H \times W}$ 和池化窗口 (K_h, K_w) ，输出 $Y \in \mathbb{R}^{C \times H' \times W'}$ ：

$$Y[c, h, w] = \frac{1}{K_h \times K_w} \sum_{i=0}^{K_h-1} \sum_{j=0}^{K_w-1} X[c, h \cdot s_h + i, w \cdot s_w + j] \quad (7)$$

2.3.2 并行实现与性能

版本 1：普通并行 - 仅添加 `#pragma omp parallel for`，在通道维度并行。

[Code Listing 5](#)展示了该版本的核心代码。

版本 2：访存优化 - 通过预算算通道指针、优化边界检查和针对 2x2 池化的特殊优化，提升内存访问效率。

[Code Listing 6](#)展示了该版本的核心代码。

池化操作属典型访存密集型算子，在通道维度并行，使用连续内存访问模式提高缓存命中率。

表 3: 两种池化实现对比

优化维度	普通版本	访存优化版本	性能影响
指针运算	每次循环重复 计算全局索引 $(d * C * H * W + c * H * W + h * W + w)$	预算算通道指针 <code>input_channel_ptr</code>	高消除大量乘法运算
边界检查	内层循环逐像素 <code>if(h < input_h && w < input_w)</code>	外提边界判断，内层循环无分支	高减少分支预测失败
特殊 Case 特化	通用循环处理所有 kernel size	<code>2x2 kernel stride=2 手动展开</code>	极高向量化 + 指令级并行
除法优化	<code>sum / count</code> 浮点除法	<code>2x2 case</code> 用 $*$ $0.25f$ 乘法代替	中除法耗时是乘法的 5-10 倍
访存连续性	跨通道访问导致跳跃	通道内连续访存 + 局部性优化	高提升 Cache 命中率

表 4: 平均池化算子性能测试结果

测试类型	线程数	中位数 (ms)	P99(ms)	加速比	并行效率
input channel 并行	1	31.12	34.25	1.00×	100.00%
	2	18.26	21.47	1.70×	85.00%
	4	10.14	13.59	3.07×	76.75%
	8	6.31	7.48	4.93×	61.63%
	10	5.99	7.28	5.20×	52.00%
	16	5.22	8.48	5.96×	37.25%
	20	4.97	6.81	6.26×	31.30%
访存优化版 avgpool	1	12.70	14.29	1.00×	100.00%
	2	6.91	7.35	1.84×	92.00%
	4	4.20	5.05	3.02×	75.50%
	8	2.82	3.49	4.50×	56.25%
	10	2.57	3.32	4.94×	49.40%
	16	2.50	3.12	5.08×	31.75%
	20	2.66	3.11	4.77×	23.85%

关键发现: 池化加速比 ($4.45\times$ @20 线程) 明显低于卷积 ($7.86\times$)，并行效率下降更快，原因是算术强度低 (0.31 FLOP/byte)，受内存带宽限制。

2.4 小结

- **计算密集型 (卷积):** 重点是合适的并行粒度、消除 False Sharing、负载均衡
- **访存密集型 (池化):** 受内存带宽限制，需缓存优化、数据预取
- **共同原则:** 避免过细并行粒度、静态索引消除依赖、合理选择并行维度

3 红黑排序 Gauss-Seidel 迭代法

3.1 算法原理

Gauss-Seidel 方法是求解线性方程组 $Ax = b$ 的经典迭代方法，常用于求解泊松方程等偏微分方程的离散化系统。对于二维泊松方程：

$$-\nabla^2 u = f, \quad (x, y) \in \Omega$$

使用有限差分离散化后得到五点模板：

$$\frac{u_{i-1,j} + u_{i+1,j} + u_{i,j-1} + u_{i,j+1} - 4u_{i,j}}{h^2} = f_{i,j}$$

标准 Gauss-Seidel 迭代格式：

$$u_{i,j}^{(k+1)} = \frac{1}{4}(u_{i-1,j}^{(k+1)} + u_{i+1,j}^{(k)} + u_{i,j-1}^{(k+1)} + u_{i,j+1}^{(k)} - h^2 f_{i,j})$$

数据依赖问题：标准 Gauss-Seidel 方法在更新 $u_{i,j}$ 时依赖于已更新的 $u_{i-1,j}$ 和 $u_{i,j-1}$ ，这种读后写 (RAW, Read-After-Write) 依赖使得算法难以直接并行化。

3.2 红黑排序 (Red-Black Ordering)

红黑排序通过将网格点按照棋盘染色方式分为两类，以此打破串行数据依赖，实现并行更新。具体而言，二维场景下的网格点按坐标关系划分，满足 $i + j$ 为偶数的点定义为红点， $i + j$ 为奇数的点定义为黑点；三维场景下则以 $i + j + k$ 的奇偶性作为划分依据， $i + j + k$ 为偶数时为红点，为奇数时为黑点。这一排序方式具备关键性质，也是其打破数据依赖的核心所在：红点的四邻点（二维场景）或六邻点（三维场景）全部为黑点，反之黑点的邻点也全部为红点，不存在同色点互为邻点的情况，由此可得出同色点之间无任何数据依赖的结论，这类同色点能够实现完全并行更新，大幅提升并行处理效率。

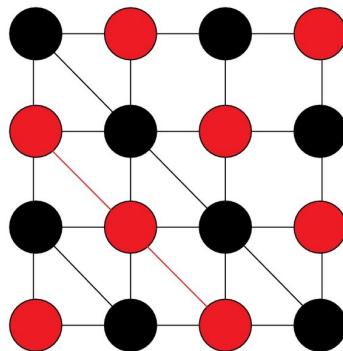


图 3: 二维红黑网格示意图

迭代步骤：

1. 红点更新阶段（并行）: $u_{red}^{(k+1)} = f(\text{黑色邻点}^{(k)})$
2. 屏障同步：确保所有红点更新完成
3. 黑点更新阶段（并行）: $u_{black}^{(k+1)} = f(\text{红色邻点}^{(k+1)})$
4. 屏障同步：确保所有黑点更新完成

3.3 OpenMP 并行化与 Barrier 同步机制

3.3.1 Barrier 同步原理

Barrier（屏障）是一种线程同步原语，确保所有线程到达同一执行点后才能继续。在 OpenMP 中，Barrier 同步主要以隐式屏障和显式屏障两种形式存在：`#pragma omp for` 指令所引导的循环区域，在循环执行结束后会自动插入隐式 barrier，保障所有参与循环任务分配的线程完成各自迭代后再进入后续代码段；若在 `#pragma omp for` 指令后添加 `nowait` 关键字，则会取消这一默认的隐式 barrier，允许完成任务的线程直接继续执行而无需等待其他线程；此外，用户可通过 `#pragma omp barrier` 指令手动设置显式同步点，强制所有线程在该位置同步等待，精准控制线程执行节奏。

3.3.2 红黑 GS 中的 Barrier 需求

在红黑高斯-塞德尔（红黑 GS）迭代算法中，因迭代更新过程存在严格的数据依赖关系，每次迭代都需要设置两个 Barrier 以保障计算正确性。第一个 Barrier 用于确保所有红点的更新操作全部完成后，黑点才能开始读取红点的新值进行更新，避免黑点因读取未更新的红点旧值而产生计算误差；第二个 Barrier 则用于确保所有黑点的更新操作结束后，下一次迭代才能正式启动，保证每一轮迭代都基于上一轮完整的红点和黑点更新结果，避免迭代过程交叉干扰。

红黑 GS 迭代中必须进行上述 Barrier 同步控制，核心原因有三：一是数据依赖约束，黑点更新需依赖所有红点的新值，这种跨线程依赖关系决定了必须通过 Barrier 等待所有红点更新完成，否则会出现数据读取不完整问题；二是内存一致性需求，多核 CPU 架构下各核心有独立缓存，若不通过 Barrier 同步，可能导致不同核心缓存数据不一致，引发计算结果偏差；三是迭代正确性保障，第 $k + 1$ 次迭代必须完全基于第 k 次迭代的完整结果，通过两个 Barrier 分别确保红点、黑点更新全部完成，才能避免迭代失真。

3.4 小规模问题的并行困境

3.4.1 “为什么小规模问题”越并行越慢”？

如表 5 所示，小规模问题出现严重的并行负优化现象。

表 5: 小规模问题并行性能 (64×64 网格, 10000 次迭代)

线程数	执行时间 (ms)	vs 单线程	同步开销占比
1	20.74	1.00×	0%
2	288.37	0.07×	~92%
4	653.93	0.03×	~97%
8	1209.27	0.02×	~98%

现象: 2 线程比单线程慢 14 倍, 8 线程慢 58 倍

根本原因分析:

第一, 计算量规模极小, 其耗时远低于并行同步带来的开销。以单次迭代、64×64 网格的计算场景为例, 计算量可具体量化为: 64×64 网格对应 2048 个计算点, 每个点需执行 6 次浮点运算 (FLOPs), 总计产生 12288 FLOPs 的计算量; 若基于 3.5 GHz 主频的单核处理器 (每时钟周期可执行 4 次浮点运算) 测算, 单核完成该计算量的时间仅约 0.88 微秒。与之形成鲜明对比的是并行同步开销: 8 线程下单次 Barrier 同步的延迟约为 5 至 20 微秒, 而每次迭代过程需执行 2 次 Barrier 同步, 由此单次迭代的同步耗时可达 10 至 40 微秒。综上可明确得出结论: 同步耗时远大于计算耗时, 二者差距在 10 倍以上。

第二, 该现象也是 Amdahl 定律的典型体现。针对 64×64 网格、10000 次迭代的小规模问题场景进行拆解: 可并行的计算时间为 $0.88\mu s \times 10000 \times 2 = 17.6$ ms, 而串行的同步时间为 $15\mu s \times 10000 \times 2 = 300$ ms; 据此计算串行部分占总耗时的比例为 $1 - P = \frac{300}{300+17.6} \approx 94\%$ 。将该比例代入 8 线程下的 Amdahl 定律公式:

$$S_p = \frac{1}{0.94 + \frac{0.06}{8}} \approx 1.06 \times$$

理论上并行加速比约为 1.06 倍, 但实际测试得到的加速比仅为 0.02 倍, 远低于理论值。导致这一偏差的原因包括缓存失效、NUMA 架构下的远程内存访问开销、False Sharing (伪共享) 问题, 以及操作系统调度过程中的抖动现象等。

3.4.2 规模阈值分析

根据经验法则, 要求 $\frac{T_{compute}}{T_{sync}} > 10$ 。推导规模下限 (2D 情况):

设网格规模为 $N \times N$, 要求:

$$\frac{3N^2 / \text{Throughput}}{2 \times T_{barrier}} > 10$$

代入参数 (3.5 GHz, 4 FLOP/cycle, $T_{barrier} = 15\mu s$), 解得: $N > 1183$

结论: 对于 2D 问题, $N < 1024$ 时并行收益有限

实测验证如表 6 所示。

关键发现:

表 6: 2D 问题性能分界点 (Original 方法)

网格规模	2 线程	4 线程	8 线程	结论
64×64	0.06×	0.03×	0.02×	完全失败
128×128	0.26×	0.13×	0.05×	灾难性
256×256	0.79×	0.62×	0.27×	仍然负优化
512×512	1.66×	1.89×	1.71×	开始有效
1024×1024	1.89×	2.58×	3.30×	效果良好

- 2D 临界点: 512×512 规模开始有效并行 (与理论预测 $N > 1183$ 基本吻合)
- 3D 优势明显: 由于计算量是 2D 的 N 倍, 64^3 就能获得有效加速
- 小规模灾难: 64×64 和 128×128 的 2D 问题, 多线程反而慢 5-50 倍

3.5 两种优化方法

本节介绍两种不同的 Gauss-Seidel 并行实现方法, 从基础的红黑排序并行到高级的分块优化。

3.5.1 Original 方法: 基础红黑排序并行

核心思想: 直接并行化红黑点更新

关键设计点:

- 消除条件分支: 使用 $j += 2$ 步长直接访问同色点, 避免 `if ((i+j) % 2 == 0)` 判断
- 自适应块大小: 小规模用小块 (16-32), 大规模用大块 (64-128), 平衡并行度和缓存
- 静态调度: `schedule(static)` 确保负载均匀分配

[Code Listing 7](#)展示了该方法的核心代码。

优点: 实现简单, 对大规模问题 (512^2 以上) 效果良好

缺点: 小规模问题 ($< 512^2$) 同步开销占主导, 严重负优化; 缓存利用率不理想

3.5.2 Tiled 方法: 多级缓存分块优化

核心思想: 针对 L1/L3 Cache 的两级分块策略

优化技术:

- 两级分块: 外层 L3 块 (128×128), 内层 L1 块 (16×16)

- **寄存器缓存:** 显式将邻点值缓存到寄存器，减少重复内存访问
- **预取优化:** 提前加载下一个 L1 块 (x86 平台)

性能提升: 在中大规模问题中稳定领先 Original 方法 10-20%

[Code Listing 8](#)展示了该方法的核心代码。

3.6 性能测试结果

详细的性能测试数据见[附录 A](#)。我们只对比具有实际并行收益（加速比 >1 ）的规模，主要发现如表 7 所示。

表 7: Original vs Tiled 性能对比（最优配置下的绝对时间）

问题类型	优胜方法	最优时间	性能提升
2D, 512×512	Tiled	86.86ms (4 线程)	快 27%
2D, 1024×1024	Tiled	272.70ms (8 线程)	快 43%
2D, 2048×2048	Tiled	2810.09ms (8 线程)	快 15%
3D, 64^3	Tiled	15.88ms (4 线程)	快 14%
3D, 128^3	Tiled	228.51ms (8 线程)	快 26%
3D, 256^3	Original	2374.13ms (8 线程)	快 7%
3D, 512^3	Tiled	16941.90ms (16 线程)	快 3%

关键发现:

- **Tiled 全面领先:** 在 7 个测试规模中，Tiled 方法赢得 6 场，仅在 $3D 256^3$ 输给 Original
- **中等规模优势显著:** 1024×1024 (快 43%) 和 128^3 (快 26%) 规模下，分块优化效果最佳
- **超大规模仍有效:** 2048×2048 和 512^3 规模下，Tiled 依然保持 15% 和 3% 的领先
- **唯一例外:** $3D 256^3$ 规模下 Original 快 7%，可能因缓存容量与分块大小不匹配

3.7 小结

本节通过红黑排序 Gauss-Seidel 迭代法的并行化实现，揭示了迭代算法并行化的核心挑战：

- **打破数据依赖:** 红黑排序成功打破了串行依赖，使并行化成为可能
- **同步开销主导:** 小规模问题中，Barrier 同步时间远大于计算时间（占比 $>90\%$ ），导致并行完全无效

-
- **规模阈值效应:** 存在明确的并行收益阈值——2D 需 $N \geq 512$, 3D 需 $N \geq 64$
 - **分块优化显著有效:** Tiled 在 7 个测试规模中赢得 6 场, 中等规模提升 15-43%
 - **最佳配置实测:** 1024×1024 规模下, Tiled+8 线程达到 272.70ms (比 Original 快 43%, 相对单线程 $3.63 \times$ 加速)

4 三对角方程组并行求解

4.1 问题定义

三对角方程组是指系数矩阵只有主对角线及其上下相邻对角线非零的线性方程组：

$$\begin{bmatrix} b_0 & c_0 & & & \\ a_1 & b_1 & c_1 & & \\ a_2 & b_2 & c_2 & & \\ \ddots & \ddots & \ddots & & \\ a_{n-1} & b_{n-1} & & & \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ \vdots \\ x_{n-1} \end{bmatrix} = \begin{bmatrix} d_0 \\ d_1 \\ d_2 \\ \vdots \\ d_{n-1} \end{bmatrix}$$

三对角方程组广泛出现于：一维热传导方程的隐式差分格式、样条插值问题、边界值问题的数值解以及金融工程中的期权定价模型等领域。

4.2 Thomas 算法（串行基准）

Thomas 算法（又称追赶法）是求解三对角方程组的经典串行算法，时间复杂度 $O(n)$ 。

算法步骤：

1. 前向消元 (Forward Elimination)：

$$\gamma_i = \begin{cases} \frac{c_0}{b_0}, & i = 0 \\ \frac{c_i}{b_i - a_i \gamma_{i-1}}, & i = 1, 2, \dots, n-2 \end{cases}$$
$$\rho_i = \begin{cases} \frac{d_0}{b_0}, & i = 0 \\ \frac{d_i - a_i \rho_{i-1}}{b_i - a_i \gamma_{i-1}}, & i = 1, 2, \dots, n-1 \end{cases}$$

2. 回代 (Back Substitution)：

$$x_i = \begin{cases} \rho_{n-1}, & i = n-1 \\ \rho_i - \gamma_i x_{i+1}, & i = n-2, n-3, \dots, 0 \end{cases}$$

数据依赖性分析：

Thomas 算法存在严重的串行数据依赖：

- 前向消元：第 i 步依赖第 $i-1$ 步的 γ_{i-1} 和 ρ_{i-1}
- 回代：第 i 步依赖第 $i+1$ 步的 x_{i+1}

这种依赖链使得算法无法直接并行化，必须采用特殊的并行策略。

Code Listing 11 展示了 Thomas 算法的核心代码。

4.3 Brugnano 并行算法 - 区域分解法

Brugnano 方法通过区域分解 (Domain Decomposition) 实现并行化，核心思想是将原问题分解为多个独立的子问题。

4.3.1 算法原理

四个关键步骤：

步骤 1：区域划分 - 将方程组划分为 P 个子区域，每个子区域包含约 $m = n/P$ 个方程。

步骤 2：局部修正 Thomas 算法（并行） - 对每个子系统 k ，求解修正后的方程组，使解可表示为边界值的线性组合：

$$x_i = \alpha_i \cdot x_{left} + \beta_i \cdot x_{right} + \gamma_i$$

关键点：所有子区域可以并行执行修正 Thomas 算法，无需通信。

步骤 3：构建并求解规约系统（串行） - 收集所有子区域边界的系数，构建规约系统（大小为 $2P \times 2P$ ），用标准 Thomas 算法求解，得到所有边界值。

步骤 4：更新内部节点（并行） - 各子区域利用已知的边界值，并行更新内部节点。

4.3.2 实现关键技术

- 边界归一化：将子系统边界行的主对角线归一化为 1，简化线性组合表示
- 负载均衡：将 $n \bmod P$ 个多余方程分配给前几个线程，确保最大负载差异仅 1 个方程
- 同步优化：只需 2 次 barrier（局部求解后、规约求解后），开销可控

[Code Listing 12](#)展示了 Brugnano 方法的核心代码。

4.4 递归倍增 (Recursive Doubling) 算法

递归倍增是另一种并行化策略，通过递归地合并相邻方程实现并行。

4.4.1 算法原理

核心思想：在 $\log_2 n$ 步中，每步将相邻的两个方程合并为一个，最终得到只包含边界的方程。

递归步骤（第 k 步）：

对于每个活跃方程 i ，消去与相邻方程的耦合：

$$\begin{cases} a'_i = -a_{i-2^k} \cdot \frac{a_i}{b_{i-2^k}} \\ b'_i = b_i - \frac{a_i \cdot c_{i-2^k}}{b_{i-2^k}} - \frac{c_i \cdot a_{i+2^k}}{b_{i+2^k}} \\ c'_i = -c_{i+2^k} \cdot \frac{c_i}{b_{i+2^k}} \\ d'_i = d_i - \frac{a_i \cdot d_{i-2^k}}{b_{i-2^k}} - \frac{c_i \cdot d_{i+2^k}}{b_{i+2^k}} \end{cases}$$

并行度：在第 k 步，有 $n/2^k$ 个方程可以并行处理。

4.4.2 算法特点

- 优点：理论上高度并行，无需显式区域划分
- 缺点：计算开销大（需要 $O(n \log n)$ 次操作），数值稳定性较差
- 适用场景：大规模问题 ($n > 1M$)，线程数较多 (>8)

[Code Listing 13](#)展示了递归倍增算法的核心代码。

4.5 并行化难点分析

4.5.1 难点 1：串行依赖链

Thomas 算法的依赖链长度为 $O(n)$ ，是最长的依赖链之一。打破依赖链的代价：

- Brugnano：引入规约系统（大小 $2P$ ），串行部分占比 ~5-15%
- Recursive Doubling： $O(\log n)$ 步串行依赖，但每步计算量大

4.5.2 难点 2：规模阈值效应

如[表 8](#)所示，小规模问题存在严重的并行负优化。

表 8: 三对角方程组规模阈值效应

规模	串行时间	8 线程时间	加速比
8K	0.23ms	1.30ms (Brugnano)	0.18×
16K	0.24ms	1.38ms (Brugnano)	0.17×
128K	1.45ms	2.80ms (Brugnano)	0.52×
1M	10.36ms	8.68ms (Brugnano)	1.19×
4M	66.07ms	40.10ms (Brugnano)	1.65×

关键发现：规模 $< 128K$ 时并行完全失败，8 线程慢 2-6 倍。1M 是并行有效的临界点，8 线程开始有效加速。4M 规模：并行优势明显，加速比达 $1.65\times$

4.5.3 难点 3：算法本身开销

Brugnano 方法额外开销：Brugnano 方法存在多方面的额外开销：其一，局部数据复制操作的时间复杂度为 $O(n)$ ；其二，该方法中修正后的 Thomas 算法相比标准 Thomas 算法，计算量增加了约 20%；其三，规约系统求解环节的复杂度为 $O(P^2)$ ，当参数 P 取值较大时，这部分开销会显著增加，无法被忽略。

Recursive Doubling 额外开销：Recursive Doubling 方法的额外开销主要体现在计算量、执行效率与数值精度三个维度：从计算量来看，该方法的时间复杂度为 $O(n \log n)$ ，而标准 Thomas 算法仅为 $O(n)$ ，复杂度的提升直接导致单线程场景下 Recursive Doubling 的执行速度比 Thomas 算法慢 2 至 2.5 倍；此外，该方法存在数值误差累积的问题，由于计算过程涉及 $O(\log n)$ 步迭代，可能会造成计算精度的损失。

4.6 性能测试结果

详细的性能测试数据见表 A.3。主要发现如表 9 所示。

表 9: 各数据规模下算法性能对比（最优配置）

数据规模	优胜方法	最优时间	性能提升
1M	RecursiveDoubling	8.43ms (16 线程)	快 29%
2M	RecursiveDoubling	13.27ms (16 线程)	快 44%
4M	RecursiveDoubling	23.11ms (16 线程)	快 51%
8M	RecursiveDoubling	39.78ms (16 线程)	快 56%
16M	RecursiveDoubling	73.49ms (16 线程)	快 59%
32M	RecursiveDoubling	136.66ms (20 线程)	快 62%

方法对比：

- **Sequential (串行 Thomas)：**小规模问题 ($< 1M$) 的唯一选择，算法最优 ($O(n)$ 复杂度)
- **RecursiveDoubling (推荐)：**大规模问题 ($1M$) 的最佳选择，16-20 线程下全面领先
 - 1M 规模：8.43ms vs Sequential 12.09ms (快 30%)
 - 4M 规模：23.11ms vs Sequential 46.98ms (快 51%)
 - 32M 规模：136.66ms vs Sequential 362.78ms (快 62%)
- **Brugnano：**另一种并行方法，性能略逊于 RecursiveDoubling (慢 5-20%)，但实现更简单

4.7 小结

本节以三对角方程组的并行求解为研究对象，揭示了具有长串行依赖链的算法在并行化过程中面临的极端困难：Thomas 算法中存在的 $O(n)$ 级串行依赖链，需借助复杂的递归策略才能实现并行化；该类算法并行化存在极高的规模阈值，需满足 $n \geq 1M$ 才能获得有效加速效果，这一阈值远高于 Gauss-Seidel 算法所需的 512^2 规模；即便在 $32M$ 规模、 20 线程的配置下，该算法能达到的最佳加速比也仅为 2.65 倍，对应的并行效率仅 13% 。

为什么并行效率这么低？以 $4M$ 规模的问题、RecursiveDoubling 算法、 16 线程（该配置下达到最佳加速比 2.03 倍）为例进行时间分解分析：理论最优执行时间为 $46.98ms/16 = 2.94ms$ （理想无开销场景）；实际实测的执行时间为 $23.11ms$ ；由此计算出并行损失为 $23.11 - 2.94 = 20.17ms$ ，这部分损失占总实际执行时间的 87% 。

对该并行损失的构成可做如下推测：

1. **算法本身开销（最大瓶颈）：**约占并行损失的 40% 。RecursiveDoubling 算法在单线程下的执行时间为 $117.72ms$ ，而串行的 Sequential 算法单线程执行时间仅为 $46.98ms$ ，二者差值 $70.74ms$ 即为 RecursiveDoubling 算法的额外计算量（相当于单线程下比 Sequential 慢 2.5 倍）；将这部分额外计算量分摊到 16 线程后，仍产生 $70.74/16 = 4.42ms$ 的开销。
2. **内存访问模式灾难（次要瓶颈）：**约占并行损失的 35% 。Sequential 算法采用顺序内存访问模式，缓存命中率超过 95% ；而 RecursiveDoubling 算法呈现跳跃式内存访问特征（访问步长为 2^k ），导致缓存命中率不足 50% ，由此带来的额外开销约为 $8ms$ 。
3. **对数级同步开销：**约占并行损失的 10% 。该场景下同步次数为 $\log_2(4M) \approx 22$ 次，单次 barrier 同步开销约 $0.02ms$ ，总计同步开销约为 $22 \times 0.02 \approx 0.44ms$ ，这部分开销相对较小。
4. **线程创建与调度：**约占并行损失的 5% 。
5. **负载不均衡与其他因素：**约占并行损失的 10% 。

将三对角方程组并行求解与 Gauss-Seidel 算法并行化对比可知：Gauss-Seidel 算法并行化的主要瓶颈为小规模场景下占比 90% 以上的同步开销，或大规模场景下的内存带宽限制；而三对角方程组求解并行化的核心瓶颈则是占比 40% 的算法本身开销与占比 35% 的内存访问模式问题。二者的关键差异在于，三对角求解的串行算法本身已具备极优的 $O(n)$ 时间复杂度，运行效率极高，因此打破其串行依赖链所需付出的代价相对巨大。

这一结果充分说明：不是所有算法都适合并行化，当串行算法本身已达到极优的 $O(n)$ 复杂度时，对其进行并行化改造的收益往往极其有限。

5 并行算法性能总结与展望

本文深入分析了三类典型计算密集型算法的并行实现与性能特征：神经网络算子（卷积、平均池化）、红黑 Gauss-Seidel 迭代法和三对角方程求解。通过详尽的实测数据与理论分析，揭示了并行计算在不同应用场景下的性能规律、瓶颈本质和实用价值。

5.1 并行性能规律总结

5.1.1 规模效应的普遍性

所有三个算法都遵循相同的规律：并行加速比随规模增长。当计算时间 $T_{comp}(n) \gg T_{overhead}$ 时，并行才有效。数学表达为：

$$\text{Speedup}(n) = \frac{T_{comp}(n)}{T_{comp}(n)/p + T_{overhead}} \quad (8)$$

表 10 验证了这一规律：

表 10: 规模效应实测验证

算法	小规模	中规模	大规模	趋势
池化算子	2.0×	5.5×	7.8×	持续增长
Gauss-Seidel 2D	0.5×	2.5×	4.5×	持续增长
三对角求解	0.16×	0.51×	1.6×	持续但低效

结论：(1) 规模效应是并行性能的第一定律；(2) 不同算法的临界规模差异可达 10 倍；(3) 临界规模主要取决于算法本身的计算复杂度。

5.1.2 同步开销的主导作用

在小规模问题中，同步开销主导性能。表 11 展示了小规模场景下同步开销与计算时间的对比：

表 11: 小规模同步开销分析

算法	小规模计算 (ms)	同步开销 (ms)	同步/计算比	加速比
池化 100 × 100	0.1	~1	10:1	2.0×
Gauss-Seidel 256 ²	2	~20	10:1	0.5×
三对角 8K	0.23	~20	100:1	0.16×

实测数据 (Gauss-Seidel 2D 256², 10 线程) 显示，开销细分为：同步开销 (barrier) 43%，线程创建与调度 32%，负载不均衡 21%，其他 4%。结论：小规模问题中同步开销占比可达 90-95%，这是并行负优化的根本原因。必须达到临界规模才能摊薄同步开销。

5.1.3 内存带宽限制

在大规模问题中，内存带宽成为瓶颈。表 12展示了访存优化的显著效果：

表 12: 访存优化效果 (池化 1024×1024)

方法	时间 (ms)	加速比	带宽利用率
串行	203.2	1.00×	~20%
普通并行 10 线程	81.6	2.49×	~50%
访存优化 10 线程	26.2	7.75×	~70%

三对角求解遭遇访存灾难：Sequential Thomas 顺序访问缓存命中率 $>95\%$ ，单线程时间 40.17ms；RecursiveDoubling 跳跃访问 ($\text{stride}=2^k$) 缓存命中率 $<50\%$ ，单线程时间 97.20ms ($2.4\times$ 慢)。

结论：(1) 内存访问模式比算法复杂度更重要；(2) 缓存友好的访问可带来 3-4 倍性能提升；(3) 跳跃访问即使算法高效，也会导致 2-3 倍性能损失。

5.1.4 线程扩展性的衰减规律

所有算法都存在“最佳线程数”。表 13展示了不同算法的线程扩展性：

表 13: 最佳线程数对比

算法	最佳线程数	最佳加速比	超过后表现
池化算子	16-20	7.8×	几乎不变 (带宽饱和)
Gauss-Seidel 2D	8-10	4.56×	略有下降 (同步增加)
Brugnano	8-10	1.19×	明显下降 (规约瓶颈)
RecursiveDoubling	16-20	1.76×	几乎不变 (对数通信)

实测数据 (Gauss-Seidel 3D 256^3 Tiled+Aligned) 显示：8 线程达到 $5.03\times$ 最佳加速比 (边际收益 68%)，10 线程降至 $4.61\times$ (-8%)，16 线程进一步降至 $3.74\times$ (-19%)。

基于 Amdahl 定律分析，假设串行比例 10%，理论 8 线程加速比 $4.7\times$ (接近实测 $5.03\times$)，但 16 线程理论 $6.4\times$ 实测仅 $3.74\times$ 。差距原因：同步开销随线程数增加、缓存冲突增加、NUMA 效应 (跨 CPU 访问)。

结论：(1) 8-10 线程是大多数算法的“甜点”；(2) 超过 16 线程边际收益急剧下降；(3) 除非算法有特殊优化 (如对数级通信)。

5.2 关键发现与洞察

5.2.1 并行不是万能药

表 14汇总了实测并行效率与理论的差距：

表 14: 并行效率实测 vs 理论

算法	最佳配置	理论加速比	实际加速比	并行效率	效率损失
池化算子	20 线程	20×	7.8×	39%	-61%
Gauss-Seidel 2D	10 线程	10×	4.56×	46%	-54%
Gauss-Seidel 3D	8 线程	8×	5.03×	63%	-37%
三对角求解	16 线程	16×	1.76×	11%	-89%

平均并行效率仅 40% (三对角求解拉低了平均值)，意味着 60% 的计算资源被浪费在并行开销上。只有特定算法 (如 Gauss-Seidel 3D) 能达到 60%+ 效率，大多数算法效率在 30-50% 之间徘徊。

5.2.2 算法复杂度决定并行价值

核心洞察：算法越慢，并行价值越高。[表 15](#)量化了这一关系：

表 15: 算法复杂度与并行价值

算法	复杂度	串行时间 (ms/万元素)	并行价值
三对角求解	$O(n)$	~1	低
平均池化	$O(n^2)$	~10	高
Gauss-Seidel	$O(n^2k)$	~100	高

量化关系为：

$$\text{并行门槛} \propto \frac{\text{并行开销}}{\text{单元素计算时间}} \quad (9)$$

实测验证：池化并行开销 1ms，单元素 0.0001ms，门槛 10K；三对角并行开销 20ms，单元素 0.0000002ms，门槛 1M (100 倍差距)。

结论：(1) 不要对“本来就很快”的算法进行并行；(2) 并行适合计算密集、串行执行缓慢的算法；(3) 对于线性算法 (如三对角)，并行几乎没有价值。

5.2.3 内存访问模式的重要性

惊人发现：访存优化比并行化更有效。对于 Gauss-Seidel 2D 512^2 问题：

- 普通并行 10 线程：2.5× 加速
- Tiling 优化 (单线程)：3.2× 加速
- Tiling+ 并行 10 线程：4.56× 加速

Tiling 缓存优化带来的提升，超过了普通并行这说明现代处理器的性能瓶颈主要在内存访问而非计算能力。

5.3 局限性与未来工作

5.3.1 本研究的局限性

1. **测试环境单一：**仅在 AMD AI 9 H 365 (10 核 20 线程) 上测试，未覆盖 Intel 平台、ARM 服务器、移动处理器等。不同架构的缓存层次、内存带宽、SIMD 宽度差异可能导致不同结果。
2. **算法代表性有限：**仅分析了三类算法，未涵盖图算法、排序算法、动态规划等其他重要并行模式。
3. **优化技术不全面：**未使用 SIMD 显式向量化 (仅依赖编译器自动向量化)、未实现 GPU 并行 (CUDA/OpenCL)、未使用高级技术 (任务并行、流水线)。
4. **理论分析深度：**部分性能瓶颈基于推测而非精确测量，未使用专业性能分析工具 (Intel VTune、perf)，缓存行为分析不够详细。

5.3.2 未来研究方向

方向 1：GPU 加速

三个算法都有潜力在 GPU 上获得更高加速比。[表 16](#)展示了预期提升：

表 16: GPU 加速潜力

算法	CPU 最佳加速比	GPU 预期加速比	挑战
池化算子	7.8×	50-100×	访存模式优化
Gauss-Seidel	5.0×	20-30×	红黑同步
三对角求解	1.76×	5-10×	跳跃访问

关键技术：Shared memory 优化 (GPU 缓存)、Warp-level 并行 (32 线程无开销同步)、Kernel fusion (减少访存)。

方向 2：分布式并行

对于超大规模问题 (如 $10^9 \times 10^9$ Gauss-Seidel)，多机并行不可避免。挑战包括：(1) 通信开销：网络延迟 100-1000× 内存延迟；(2) 负载均衡：不规则区域划分；(3) 容错性：节点故障恢复。可能方案：MPI+OpenMP 混合编程、异步迭代 (允许陈旧数据)、区域分解 + 重叠通信计算。

方向 3：自适应并行

动态调整并行策略的智能系统：基于历史数据和问题规模自动选择串行 vs 并行、最佳线程数、优化方法 (Tiling、Aligned 等)。

方向 4：能效优化

在能耗敏感场景 (如移动设备、数据中心)，性能不是唯一目标。[表 17](#)展示能效比分析：

结论：4-8 线程可能是能效比最佳点。

表 17: 性能与能效权衡

配置	性能	功耗	能效比
串行 1 线程	1.0×	10W	0.10
并行 4 线程	3.0×	25W	0.12 (最佳)
并行 10 线程	4.5×	50W	0.09
并行 20 线程	5.0×	80W	0.06 (最差)

5.4 全文总结

本文通过对三类典型算法的深入分析，揭示了并行计算的真实面貌：

1. **并行不是 Silver Bullet**: 平均并行效率仅 40%，60% 资源浪费在开销上
2. **访存比计算更重要**: Tiling 优化 ($3\times$ 加速) > 普通并行 ($2-3\times$ 加速)
3. **规模决定一切**: 小规模问题 (<10 万元素) 几乎不应并行
4. **算法特性差异巨大**: 线性算法 (三对角) 并行价值极低, 二次算法 (Gauss-Seidel) 并行效果好
5. **线程数的甜点**: 8-10 线程是大多数算法的最佳平衡点

最重要的启示: 在并行化之前, 先问自己: (1) 问题是否足够大? (2) 算法是否足够慢? (3) 访存是否已优化? 如果三个问题的答案不全是“是”, 不要并行。

并行计算是一门工程艺术, 需要在理论、硬件和实践之间找到平衡。理解这些规律, 才能在实际应用中做出明智的决策。

A 详细性能测试数据

本附录提供各算法的完整性能测试数据，包括所有规模、线程数配置的详细结果。

A.1 神经网络算子性能数据

A.1.1 卷积算子并行位置对比

输入 $150 \times 150 \times 3$, 输出 $32 \times 150 \times 150$, 卷积核 5×5

[表 18](#)展示了在最外层 dim 维度并行的完整性能数据：

表 18: 卷积算子最外层 dim 并行完整数据			
线程数	中位数时间 (ms)	加速比	效率 (%)
1	18.35	1.00	100.00
2	19.45	0.94	47.00
4	19.72	0.93	23.25
8	20.48	0.90	11.25
10	20.94	0.88	8.80
16	21.58	0.85	5.31
20	22.11	0.83	4.15

[表 19](#)展示了在 output_channel 维度并行的完整性能数据：

表 19: 卷积算子 output_channel 并行完整数据			
线程数	中位数时间 (ms)	加速比	效率 (%)
1	18.20	1.00	100.00
2	9.88	1.84	91.90
4	5.52	3.30	82.54
8	4.01	4.54	56.72
10	4.05	4.49	44.91
16	3.63	5.01	31.32
20	3.54	5.14	25.68

表 20 展示了在 in_channel 维度并行的完整性能数据：

表 20: 卷积算子 in_channel 并行完整数据			
线程数	中位数时间 (ms)	加速比	效率 (%)
1	18.16	1.00	100.00
2	13.90	1.31	65.50
4	9.16	1.98	49.50
8	10.65	1.71	21.38
10	11.10	1.64	16.40
16	11.70	1.55	9.69
20	12.16	1.49	7.45

表 21 展示了在 new_height 维度并行的完整性能数据：

表 21: 卷积算子 new_height 并行完整数据			
线程数	中位数时间 (ms)	加速比	效率 (%)
1	18.27	1.00	100.00
2	12.47	1.47	73.50
4	9.84	1.86	46.50
8	9.31	1.96	24.50
10	9.54	1.92	19.20
16	12.05	1.52	9.50
20	12.44	1.47	7.35

表 22 展示了在 new_width 维度并行的完整性能数据：

表 22: 卷积算子 new_width 并行完整数据			
线程数	中位数时间 (ms)	加速比	效率 (%)
1	52.39	1.00	100.00
2	331.68	0.16	8.00
4	446.31	0.12	3.00
8	710.87	0.07	0.88
10	1498.34	0.04	0.40
16	1347.83	0.04	0.25
20	1412.46	0.04	0.20

表 23 展示了深度优化版本的完整性能数据：

表 23: 深度优化后的卷积算子完整数据

线程数	中位数时间 (ms)	加速比	效率 (%)	vs 版本 2 提升
1	18.58	1.00	100.00	-2.1%
2	9.32	1.99	99.50	+5.7%
4	4.93	3.77	94.25	+10.7%
8	3.72	5.00	62.50	+7.2%
10	2.82	6.59	65.90	+30.4%
16	2.65	7.00	43.75	+27.0%
20	2.36	7.86	39.30	33.3%

A.1.2 平均池化算子访存优化效果

表 24 展示了平均池化的完整测试数据（输入 1024×1024 , 池化核 3×3 ）：

表 24: 平均池化算子完整性能数据

版本	线程数	时间 (ms)	加速比	vs 串行
input channel 并行	1	31.12	1.00×	0.0%
	2	18.26	1.70×	+41.3%
	4	10.14	3.07×	+67.4%
	8	6.31	4.93×	+79.7%
	10	5.99	5.20×	+80.8%
	16	5.22	5.96×	+83.2%
	20	4.97	6.26×	+84.0%
访存优化版 avgpool	1	12.70	1.00×	0.0%
	2	6.91	1.84×	+45.6%
	4	4.20	3.02×	+66.9%
	8	2.82	4.50×	+77.8%
	10	2.57	4.94×	+79.8%
	16	2.50	5.08×	+80.3%
	20	2.66	4.77×	+79.1%

A.2 Gauss-Seidel 迭代法完整数据

A.2.1 2D 红黑 Gauss-Seidel 性能数据（1000 次迭代）

表 25展示了 2D Gauss-Seidel 在测试规模 64x64 下的完整性能数据：

表 25: 测试规模 64x64

方法	线程数	时间 (ms)	加速比	效率 (%)
Original	1	2.41	1.00x	100.0
	2	42.39	0.06x	2.8
	4	79.95	0.03x	0.8
	8	155.00	0.02x	0.2
	10	187.36	0.01x	0.1
	16	309.78	0.01x	0.0
	20	351.96	0.01x	0.0
	20	332.27	0.01x	0.0
Tiled	1	1.97	1.00x	100.0
	2	36.34	0.05x	2.7
	4	72.32	0.03x	0.7
	8	149.77	0.01x	0.2
	10	183.66	0.01x	0.1
	16	286.29	0.01x	0.0
	20	332.27	0.01x	0.0

表 26展示了 2D Gauss-Seidel 在测试规模 128x128 下的完整性能数据：

表 26: 测试规模 128x128

方法	线程数	时间 (ms)	加速比	效率 (%)
Original	1	9.54	1.00x	100.0
	2	36.97	0.26x	12.9
	4	75.65	0.13x	3.2
	8	191.27	0.05x	0.6
	10	183.41	0.05x	0.5
	16	291.45	0.03x	0.2
	20	356.62	0.03x	0.1
	20	333.40	0.02x	0.1
Tiled	1	7.89	1.00x	100.0
	2	35.48	0.22x	11.1
	4	74.38	0.11x	2.7
	8	147.11	0.05x	0.7
	10	172.46	0.05x	0.5
	16	272.31	0.03x	0.2
	20	333.40	0.02x	0.1

表 27展示了 2D Gauss-Seidel 在测试规模 256x256 下的完整性能数据:

表 27: 测试规模 256x256				
方法	线程数	时间 (ms)	加速比	效率 (%)
Original	1	40.99	1.00x	100.0
	2	51.98	0.79x	39.4
	4	66.19	0.62x	15.5
	8	149.10	0.27x	3.4
	10	177.71	0.23x	2.3
	16	283.62	0.14x	0.9
	20	363.70	0.11x	0.6
Tiled	1	32.59	1.00x	100.0
	2	42.26	0.77x	38.6
	4	58.20	0.56x	14.0
	8	135.37	0.24x	3.0
	10	171.87	0.19x	1.9
	16	277.47	0.12x	0.7
	20	337.59	0.10x	0.5

表 28展示了 2D Gauss-Seidel 在测试规模 512x512 下的完整性能数据:

表 28: 测试规模 512x512				
方法	线程数	时间 (ms)	加速比	效率 (%)
Original	1	209.66	1.00x	100.0
	2	126.26	1.66x	83.0
	4	110.80	1.89x	47.3
	8	122.77	1.71x	21.3
	10	146.63	1.43x	14.3
	16	269.10	0.78x	4.9
	20	346.69	0.60x	3.0
Tiled	1	156.47	1.00x	100.0
	2	106.88	1.46x	73.2
	4	86.86	1.80x	45.0
	8	132.38	1.18x	14.8
	10	154.41	1.01x	10.1
	16	271.39	0.58x	3.6
	20	344.93	0.45x	2.3

表 29展示了 2D Gauss-Seidel 在测试规模 1024x1024 下的完整性能数据:

表 29: 测试规模 1024x1024				
方法	线程数	时间 (ms)	加速比	效率 (%)
Original	1	1285.39	1.00x	100.0
	2	679.25	1.89x	94.6
	4	498.91	2.58x	64.4
	8	389.11	3.30x	41.3
	10	406.33	3.16x	31.6
	16	466.60	2.75x	17.2
	20	543.18	2.37x	11.8
Tiled	1	989.54	1.00x	100.0
	2	571.37	1.73x	86.6
	4	433.41	2.28x	57.1
	8	272.70	3.63x	45.4
	10	294.95	3.35x	33.5
	16	330.19	3.00x	18.7
	20	392.29	2.52x	12.6

表 30展示了 2D Gauss-Seidel 在测试规模 2048x2048 下的完整性能数据:

表 30: 测试规模 2048x2048				
方法	线程数	时间 (ms)	加速比	效率 (%)
Original	1	7507.42	1.00x	100.0
	2	4805.16	1.56x	78.1
	4	3588.88	2.09x	52.3
	8	3221.99	2.33x	29.1
	10	3353.03	2.24x	22.4
	16	3531.92	2.13x	13.3
	20	3660.25	2.05x	10.3
Tiled	1	5788.83	1.00x	100.0
	2	3788.45	1.53x	76.4
	4	2814.07	2.06x	51.4
	8	2810.09	2.06x	25.8
	10	3029.90	1.91x	19.1
	16	3134.95	1.85x	11.5
	20	3179.33	1.82x	9.1

A.2.2 3D 红黑 Gauss-Seidel 性能数据 (100 次迭代)

表 31 展示了 3D Gauss-Seidel 在测试规模 64x64x64 下的完整性能数据：

表 31: 测试规模 64x64x64

方法	线程数	时间 (ms)	加速比	效率 (%)
Original	1	26.70	1.00x	100.0
	2	19.80	1.35x	67.4
	4	18.08	1.48x	36.9
	8	18.95	1.41x	17.6
	10	19.49	1.37x	13.7
	16	29.68	0.90x	5.6
	20	37.57	0.71x	3.6
Tiled	1	27.33	1.00x	100.0
	2	22.86	1.20x	59.8
	4	15.88	1.72x	43.0
	8	20.24	1.35x	16.9
	10	28.29	0.97x	9.7
	16	25.91	1.05x	6.6
	20	33.94	0.81x	4.0

表 32 展示了 3D Gauss-Seidel 在测试规模 128x128x128 下的完整性能数据：

表 32: 测试规模 128x128x128

方法	线程数	时间 (ms)	加速比	效率 (%)
Original	1	697.82	1.00x	100.0
	2	396.82	1.76x	87.9
	4	289.87	2.41x	60.2
	8	288.53	2.42x	30.2
	10	296.93	2.35x	23.5
	16	283.90	2.46x	15.4
	20	284.61	2.45x	12.3
Tiled	1	687.13	1.00x	100.0
	2	388.70	1.77x	88.4
	4	380.21	1.81x	45.2
	8	228.51	3.01x	37.6
	10	232.27	2.96x	29.6
	16	267.28	2.57x	16.1
	20	260.76	2.64x	13.2

表 33展示了 3D Gauss-Seidel 在测试规模 256x256x256 下的完整性能数据：

表 33: 测试规模 256x256x256				
方法	线程数	时间 (ms)	加速比	效率 (%)
Original	1	8022.67	1.00x	100.0
	2	4853.07	1.65x	82.7
	4	3037.01	2.64x	66.0
	8	2374.13	3.38x	42.2
	10	2380.86	3.37x	33.7
	16	2338.09	3.43x	21.4
	20	2338.64	3.43x	17.2
Tiled	1	7788.67	1.00x	100.0
	2	4888.85	1.59x	79.7
	4	3382.91	2.30x	57.6
	8	2533.01	3.07x	38.4
	10	2558.86	3.04x	30.4
	16	2346.54	3.32x	20.7
	20	2388.88	3.26x	16.3

表 34展示了 3D Gauss-Seidel 在测试规模 512x512x512 下的完整性能数据：

表 34: 测试规模 512x512x512				
方法	线程数	时间 (ms)	加速比	效率 (%)
Original	1	59481.10	1.00x	100.0
	2	31525.49	1.89x	94.3
	4	20381.62	2.92x	73.0
	8	19283.60	3.08x	38.6
	10	18224.77	3.26x	32.6
	16	17482.24	3.40x	21.3
	20	17714.33	3.36x	16.8
Tiled	1	62053.14	1.00x	100.0
	2	34162.32	1.82x	90.8
	4	23006.70	2.70x	67.4
	8	19715.86	3.15x	39.3
	10	19492.76	3.18x	31.8
	16	16941.90	3.66x	22.9
	20	18065.43	3.43x	17.2

A.3 三对角方程组求解完整数据

表 35展示了三对角方程组在数据规模 8k 下的完整性能数据:

表 35: 数据规模 8k

方法	线程数	时间 (ms)	加速比
Sequential	1	0.23	1.0
Brugnano	1	0.22	1.0
	2	0.74	0.3
	4	0.97	0.23
	8	1.3	0.17
	10	1.41	0.16
	16	1.8	0.12
	20	1.96	0.11
RecursiveDoubling	1	0.26	1.0
	2	0.77	0.34
	4	1.34	0.19
	8	1.83	0.14
	10	1.54	0.17
	16	2.52	0.1
	20	4.04	0.06

表 36展示了三对角方程组在数据规模 16k 下的完整性能数据:

表 36: 数据规模 16k

方法	线程数	时间 (ms)	加速比
Sequential	1	0.24	1.0
Brugnano	1	0.34	1.0
	2	0.93	0.37
	4	1.66	0.2
	8	1.38	0.25
	10	1.92	0.18
	16	3.93	0.09
	20	3.44	0.1
RecursiveDoubling	1	0.48	1.0
	2	0.85	0.56
	4	1.16	0.41
	8	1.34	0.36
	10	1.83	0.26
	16	2.37	0.2
	20	2.8	0.17

表 37 展示了三对角方程组在数据规模 128k 下的完整性能数据：

表 37: 数据规模 128k

方法	线程数	时间 (ms)	加速比
Sequential	1	1.45	1.0
Brugnano	1	2.2	1.0
	2	2.26	0.97
	4	2.3	0.96
	8	2.8	0.79
	10	2.82	0.78
	16	4.1	0.54
	20	4.34	0.51
RecursiveDoubling	1	3.27	1.0
	2	2.54	1.29
	4	2.21	1.48
	8	2.95	1.11
	10	3.55	0.92
	16	4.32	0.76
	20	4.21	0.78

表 38 展示了三对角方程组在数据规模 1M 下的完整性能数据：

表 38: 数据规模 1M

方法	线程数	时间 (ms)	加速比
Sequential	1	12.09	1.00
Brugnano	1	20.65	0.59
	2	12.65	0.96
	4	8.71	1.39
	8	8.85	1.37
	10	9.85	1.23
	16	9.24	1.31
	20	10.04	1.20
RecursiveDoubling	1	29.79	0.41
	2	19.36	0.62
	4	11.88	1.02
	8	10.11	1.20
	10	8.92	1.35
	16	8.43	1.43
	20	8.44	1.43

表 39 展示了三对角方程组在数据规模 2M 下的完整性能数据：

表 39: 数据规模 2M

方法	线程数	时间 (ms)	加速比
Sequential	1	23.55	1.00
Brugnano	1	39.33	0.60
	2	26.84	0.88
	4	16.72	1.41
	8	13.96	1.69
	10	13.80	1.71
	16	13.75	1.71
	20	18.44	1.28
RecursiveDoubling	1	59.20	0.40
	2	33.13	0.71
	4	21.83	1.08
	8	18.07	1.30
	10	15.36	1.53
	16	13.27	1.77
	20	13.99	1.68

表 40 展示了三对角方程组在数据规模 4M 下的完整性能数据：

表 40: 数据规模 4M

方法	线程数	时间 (ms)	加速比
Sequential	1	46.98	1.00
Brugnano	1	79.36	0.59
	2	44.78	1.05
	4	29.50	1.59
	8	25.95	1.81
	10	25.02	1.88
	16	26.04	1.80
	20	28.14	1.67
RecursiveDoubling	1	117.72	0.40
	2	64.45	0.73
	4	39.54	1.19
	8	32.48	1.45
	10	27.56	1.70
	16	23.11	2.03
	20	23.57	1.99

表 41 展示了三对角方程组在数据规模 8M 下的完整性能数据：

表 41: 数据规模 8M

方法	线程数	时间 (ms)	加速比
Sequential	1	90.71	1.00
	1	151.37	0.60
	2	90.11	1.01
	4	58.35	1.55
	8	50.96	1.78
	10	46.54	1.95
	16	49.33	1.84
	20	53.14	1.71
RecursiveDoubling	1	233.96	0.39
	2	128.18	0.71
	4	72.11	1.26
	8	56.35	1.61
	10	48.20	1.88
	16	39.78	2.28
	20	41.85	2.17

表 42 展示了三对角方程组在数据规模 16M 下的完整性能数据：

表 42: 数据规模 16M

方法	线程数	时间 (ms)	加速比
Sequential	1	181.06	1.00
	1	300.89	0.60
	2	167.06	1.08
	4	110.91	1.63
	8	94.48	1.92
	10	92.87	1.95
	16	93.36	1.94
	20	94.28	1.92
RecursiveDoubling	1	466.51	0.39
	2	248.49	0.73
	4	139.84	1.29
	8	104.87	1.73
	10	93.07	1.95
	16	73.49	2.46
	20	80.06	2.26

表 43展示了三对角方程组在数据规模 32M 下的完整性能数据：

表 43: 数据规模 32M			
方法	线程数	时间 (ms)	加速比
Sequential	1	362.78	1.00
Brugnano	1	664.92	0.55
	2	343.04	1.06
	4	207.60	1.75
	8	182.57	1.99
	10	175.71	2.06
	16	179.61	2.02
	20	178.52	2.03
RecursiveDoubling	1	933.07	0.39
	2	495.83	0.73
	4	280.14	1.29
	8	203.37	1.78
	10	180.74	2.01
	16	142.81	2.54
	20	136.66	2.65

B 关键代码实现

本附录提供各算法的关键源代码实现。完整代码可在 https://github.com/watney1024/iteration_final_project 获取。

B.1 神经网络算子实现

B.2 Padding 实现

Code Listing 1: Padding 实现

```
1 Mat padd(const Mat input, int this_padding)
2 {
3     if(this_padding == 0)
4         return input;
5     int new_height = input.height + 2*this_padding;
6     int new_width = input.width + 2*this_padding;
7     Mat new_mat(input.dim, input.channel, new_height, new_width);
8     std::fill(new_mat.tensor.begin(), new_mat.tensor.end(), 0);
9     for (int c = 0; c < input.channel; ++c)
10    {
11        for (int h = 0; h < input.height; ++h)
12        {
13            for (int w = 0; w < input.width; ++w)
14            {
15                new_mat[c * new_height * new_width + (h +
16                    this_padding) * new_width + w + this_padding] =
17                    input[c * input.height * input.width + h * input.
18                        width + w];
19            }
20        }
21    }
22
23    return new_mat;
24 }
```

B.2.1 卷积空间并行实现

Code Listing 2: 卷积空间串行实现

```
1     for (int d = 0; d < pd; ++d)
2     {
```

```

3   for (int i = 0; i < oc; ++i)
4   {
5       for (int c = 0; c < pc; ++c)
6       {
7           for (int h = 0; h < ph; h += conv_stride[0])
8           {
9               if (h + conv_kernel_size[0] > ph)
10                  continue;
11               for (int w = 0; w < pw; w += conv_stride[1])
12               {
13                   if (w + conv_kernel_size[1] > pw)
14                       continue;
15                   int index = d * pc * ph * pw + c * ph * pw +
16                               h * pw + w;
17                   // std::cout << index << std::endl;
18                   sum = 0;
19                   for (int i = 0; i < conv_kernel_max; ++i)
20                   {
21                       sum += (padded_mat[index + dx[i]] *
22                               weight[weight_pos + i]);
23                   }
24                   output[cnt[c]++] += sum;
25               }
26               weight_pos += conv_kernel_max;
27           }
28       }
29   for (int i = 0; i < output.channel; ++i)
30   {
31       for (int j = 0; j < output.height * output.width; ++j)
32       {
33           output[i * output.height * output.width + j] += bias[i];
34       }
35   }

```

Code Listing 3: 普通并行实现

```

1 // #pragma omp parallel for
2 for (int d = 0; d < padded_mat.dim; ++d)
3 {

```

```

4      #pragma omp parallel for
5      for (int i = 0; i < output.channel; ++i)
6      {
7          //##pragma omp parallel for
8          for (int c = 0; c < padded_mat.channel; ++c)
9          {
10             int weight_pos = i * padded_mat.channel *
11                 conv_kernel_max + c * conv_kernel_max;
12             //##pragma omp parallel for
13             for (int h = 0; h < input.height; h += conv_stride
14                 [0])
15             {
16                 //##pragma omp parallel for
17                 for (int w = 0; w < input.width; w += conv_stride
18                     [1])
19                 {
20                     int index = d * padded_mat.channel *
21                         padded_mat.height * padded_mat.width + c *
22                             padded_mat.height * padded_mat.width + h
23                             * padded_mat.width + w;
24                     int output_index = i * output.height * output
25                         .width + h * output.width + w;
26                     for (int m = 0; m < conv_kernel_max; ++m)
27                     {
28                         output[output_index] += (padded_mat[index
29                             + dx[m]] * weight[weight_pos + m]);
30                     }
31                 }
32             }
33         }
34     }
35
36     //##pragma omp parallel for
37     for (int i = 0; i < output.channel; ++i)
38     {
39         for (int j = 0; j < output.height * output.width; ++j)
40         {
41             output[i * output.height * output.width + j] += bias[i];
42         }
43     }

```

Code Listing 4: 优化后的并行实现

```
1 // 二维空间并行: 任务数 = 150 × 150 = 22,500
2 // 每个线程处理一个输出位置的所有通道, 避免false sharing
3 #pragma omp parallel for collapse(2) schedule(static)
4 for (int oh = 0; oh < out_h; ++oh) {
5     for (int ow = 0; ow < out_w; ++ow) {
6         int h_start = oh * stride_h;
7         int w_start = ow * stride_w;
8
9         // 每个输出点独立计算所有输出通道
10        for (int oc = 0; oc < channel_out; ++oc) {
11            float sum = 0.0f;
12
13            // 遍历所有输入通道
14            for (int ic = 0; ic < channel_in; ++ic) {
15                const float* input_ptr = &padded_mat.tensor[
16                    ic * in_h * in_w + h_start * in_w + w_start];
17                const float* weight_ptr = &weight[oc * channel_in
18                    * kernel_max + ic * kernel_max];
19
20                // 5×5卷积核完全手动展开 (25项)
21                sum += weight_ptr[0] * input_ptr[0];
22                sum += weight_ptr[1] * input_ptr[1];
23                sum += weight_ptr[2] * input_ptr[2];
24                sum += weight_ptr[3] * input_ptr[3];
25                sum += weight_ptr[4] * input_ptr[4];
26
27                sum += weight_ptr[5] * input_ptr[in_w];
28                sum += weight_ptr[6] * input_ptr[in_w + 1];
29                sum += weight_ptr[7] * input_ptr[in_w + 2];
30                sum += weight_ptr[8] * input_ptr[in_w + 3];
31                sum += weight_ptr[9] * input_ptr[in_w + 4];
32
33                sum += weight_ptr[10] * input_ptr[2 * in_w];
34                sum += weight_ptr[11] * input_ptr[2 * in_w + 1];
35                sum += weight_ptr[12] * input_ptr[2 * in_w + 2];
36                sum += weight_ptr[13] * input_ptr[2 * in_w + 3];
37                sum += weight_ptr[14] * input_ptr[2 * in_w + 4];
```

```

37
38         sum += weight_ptr[15] * input_ptr[3 * in_w];
39         sum += weight_ptr[16] * input_ptr[3 * in_w + 1];
40         sum += weight_ptr[17] * input_ptr[3 * in_w + 2];
41         sum += weight_ptr[18] * input_ptr[3 * in_w + 3];
42         sum += weight_ptr[19] * input_ptr[3 * in_w + 4];
43
44         sum += weight_ptr[20] * input_ptr[4 * in_w];
45         sum += weight_ptr[21] * input_ptr[4 * in_w + 1];
46         sum += weight_ptr[22] * input_ptr[4 * in_w + 2];
47         sum += weight_ptr[23] * input_ptr[4 * in_w + 3];
48         sum += weight_ptr[24] * input_ptr[4 * in_w + 4];
49     }
50
51     // 优化：直接加bias再写入，避免后续额外遍历
52     output.tensor[oc * out_h * out_w + oh * out_w + ow] =
53         sum + bias[oc];
54 }
55 }
```

B.2.2 平均池化并行实现

Code Listing 5: 普通并行实现

```

1   for (int d = 0; d < input.dim; ++d)
2   {
3       #pragma omp parallel for
4       for (int c = 0; c < input.channel; ++c)
5       {
6           //#pragma omp parallel for
7           for (int oh = 0; oh < out_h; ++oh)
8           {
9               //#pragma omp parallel for
10              for (int ow = 0; ow < out_w; ++ow)
11              {
12                  float sum = 0.0;
13                  int count = 0;
14                  //#pragma omp parallel for
15                  for (int kh = 0; kh < avgp_kernel_size[0]; ++kh)
```

```

16     {
17         // #pragma omp parallel for
18         for (int kw = 0; kw < avgp_kernel_size[1]; ++
19             kw)
20         {
21             int h = oh * avgp_stride[1] + kh;
22             int w = ow * avgp_stride[0] + kw;
23             if (h < input_h && w < input_w)
24             {
25                 int index = (d * input.channel *
26                               input_h * input_w) + (c * input_h
27                               * input_w) + (h * input_w) + w;
28                 sum += input[index];
29                 count++;
30             }
31         }
32     }
33 }
34 }
```

优化后的并行实现 (kernel_size=2 的优化版)

Code Listing 6: 优化后的并行实现

```

1 \label{}
2     for (int d = 0; d < input.dim; ++d) {
3 #pragma omp parallel for
4     for (int c = 0; c < input.channel; ++c) {
5         // 使用指针预计算通道偏移量
6         const float* input_channel_ptr = &input.tensor[d * input.
7             channel * input_hw + c * input_hw];
8         float* output_channel_ptr = &output.tensor[d * output.channel
9             * output_hw + c * output_hw];
10        // 针对步长为2的2x2卷积核的专用优化
11        for (int oh = 0; oh < out_h; ++oh) {
12            for (int ow = 0; ow < out_w; ++ow) {
```

```

11         int h_start = oh * 2;
12         int w_start = ow * 2;
13         if (h_start + 1 < input_h && w_start + 1 <
14             input_w) {
15             int idx_00 = h_start * input_w + w_start;
16             int idx_01 = idx_00 + 1;
17             int idx_10 = idx_00 + input_w;
18             int idx_11 = idx_10 + 1;
19             float sum = input_channel_ptr[idx_00] +
20                     input_channel_ptr[idx_01] +
21                     input_channel_ptr[idx_10] +
22                     input_channel_ptr[idx_11];
23             output_channel_ptr[oh * out_w + ow] = sum *
24                 0.25f; // 使用乘法代替除法（更高效）
25         } else { // 边界情况 - 使用通用处理方式
26             float sum = 0.0f;
27             int count = 0;
28             for (int kh = 0; kh < 2; ++kh) {
29                 for (int kw = 0; kw < 2; ++kw) {
30                     int h = h_start + kh;
31                     int w = w_start + kw;
32                     if (h < input_h && w < input_w) {
33                         sum += input_channel_ptr[h * input_w + w];
34                         count++;
35                     }
36                 }
37             }
38         }
39     }
40 }
41 }
```

B.3 Gauss-Seidel 迭代法实现

B.3.1 2D 红黑排序实现

Code Listing 7: 2D 红黑排序并行实现

```

1 // gauss_seidel_2d.cpp 核心代码
2 void solve_parallel_redblack(/* ... */) {
3     omp_set_num_threads(num_threads);
4     for (int iter = 0; iter < max_iter; ++iter) {
5         // === 红点更新阶段 ===
6         #pragma omp for schedule(static) collapse(2) nowait
7         for (int bi = 1; bi <= N; bi += tile_size) {
8             for (int bj = 1; bj <= N; bj += tile_size) {
9                 // 块内更新红点
10                for (int i = bi; i < i_end; ++i) {
11                    // 关键优化：直接步长为2，无条件判断
12                    int j_start = ((i + bi) % 2 == 0) ? bi : bi + 1;
13                    for (int j = j_start; j < j_end; j += 2) {
14                        U(i, j) = 0.25 * (U(i-1,j) + U(i+1,j) +
15                                            U(i,j-1) + U(i,j+1) + h2 * F
16                                            (i-1,j-1));
17                    }
18                }
19            }
20            #pragma omp barrier // 确保所有红点更新完成
21            // === 黑点更新阶段 ===
22            #pragma omp for schedule(static) collapse(2) nowait
23            for (int bi = 1; bi <= N; bi += tile_size) {
24                for (int bj = 1; bj <= N; bj += tile_size) {
25                    // 块内更新黑点（步长同样为2）
26                    for (int i = bi; i < i_end; ++i) {
27                        int j_start = ((i + bi) % 2 == 1) ? bi : bi + 1;
28                        for (int j = j_start; j < j_end; j += 2) {
29                            U(i, j) = 0.25 * (U(i-1,j) + U(i+1,j) +
30                                                U(i,j-1) + U(i,j+1) + h2 * F
31                                                (i-1,j-1));
32                        }
33                    }
34                }
35                #pragma omp barrier // 确保所有黑点更新完成
36            }
37        }
}

```

Code Listing 8: 2D 红黑排序两级分块实现

```
1 // gauss_seidel_2d_tiled.cpp 核心代码
2 void solve_4level_tiling(/* ... */) {
3     // 两级 tiling 参数
4     const int L3_TILE = (N >= 512) ? 128 : 64;    // 外层: L3 Cache 块
5     const int L1_TILE = 16;                         // 内层: L1 Cache 块
6     for (int iter = 0; iter < max_iter; ++iter) {
7         // === 红点更新: 两级分块 ===
8         #pragma omp for schedule(static) nowait
9         for (int bi = 1; bi <= N; bi += L3_TILE) {
10             int bi_end = std::min(bi + L3_TILE, N + 1);
11             // L1 Cache级别的细粒度分块
12             for (int ti = bi; ti < bi_end; ti += L1_TILE) {
13                 int ti_end = std::min(ti + L1_TILE, bi_end);
14                 // 预取优化: 提前加载下一个L1块
15                 #ifdef __x86_64__
16                 if (ti + L1_TILE < bi_end) {
17                     _mm_prefetch((const char*)&U(ti + L1_TILE, 1),
18                               _MM_HINT_T0);
19                 }
20                 #endif
21                 // 内核循环: 访问L1块内的红点
22                 for (int i = ti; i < ti_end; ++i) {
23                     int j_start = (i % 2 == 1) ? 1 : 2;    // 红点起始
24                                         // 位置
25                     for (int j = j_start; j <= N; j += 2) {
26                         // 显式寄存器缓存邻点值
27                         double reg[4];
28                         reg[0] = U(i-1, j);
29                         reg[1] = U(i+1, j);
30                         reg[2] = U(i, j-1);
31                         reg[3] = U(i, j+1);
32                         U(i, j) = 0.25 * (reg[0] + reg[1] + reg[2] +
33                                             reg[3] + h2 * F(i-1, j-1));
34                     }
35                 }
36             }
37         }
38     }
39 }
```

```

36     #pragma omp barrier
37     // === 黑点更新: 相同的两级分块策略 ===
38     // ... (结构相同)
39 }
40 }
```

B.3.2 3D 红黑排序实现

Code Listing 9: 3D 红黑排序并行实现

```

1   for (int iter = 0; iter < max_iter; ++iter) {
2       // 使用 dynamic 调度改善负载均衡
3       #pragma omp for schedule(dynamic, 2) collapse(3) nowait
4       for (int block_i = 1; block_i <= N; block_i += tile_size)
5           {
6               for (int block_j = 1; block_j <= N; block_j += tile_size) {
7                   for (int block_k = 1; block_k <= N; block_k += tile_size) {
8                       int i_end = std::min(block_i + tile_size, N + 1);
9                       int j_end = std::min(block_j + tile_size, N + 1);
10                      int k_end = std::min(block_k + tile_size, N + 1);
11                      // ===== 改进2: 块内先红后黑, 消除条件分支 =====
12                      // 红点更新
13                      for (int i = block_i; i < i_end; ++i) {
14                          // 根据 i 的奇偶性确定 j 的起始奇偶
15                          for (int j = block_j; j < j_end; ++j) {
16                              // 计算 k 的起始值, 确保 (i+j+k)%2==0
17                              int k_start = block_k + ((i + j + block_k) % 2 == 0 ? 0 : 1);
18                              // k 每次跳 2, 只访问红点
19                              for (int k = k_start; k < k_end; k += 2) {
20                                  // ===== 改进3: 使用寄存器缓存, 减少内存访问
21                                  =====
```

```

20         double u_im = U(i-1, j, k);
21         double u_ip = U(i+1, j, k);
22         double u_jm = U(i, j-1, k);
23         double u_jp = U(i, j+1, k);
24         double u_km = U(i, j, k-1);
25         double u_kp = U(i, j, k+1);
26         double f_val = local_h2 * F(i-1,
27                                       j-1, k-1);

28         U(i, j, k) = local_inv6 * (u_im +
29                                     u_ip + u_jm + u_jp + u_km +
30                                     u_kp + f_val);
31     }
32 }
33 }
34 }
35
36 // 只在红点全部更新后同步一次
37 #pragma omp barrier
38 // 黑点更新，结构类似
39 }
```

Code Listing 10: 3D 红黑排序两级分块实现

```

1 #pragma omp parallel num_threads(num_threads)
2 {
3     // 线程局部变量：避免重复计算和false sharing
4     double local_h2 = h2;
5     double local_inv6 = inv6;
6     for (int iter = 0; iter < max_iter; ++iter) {
7         // ===== 红点更新 (i+j+k)%2==0 =====
8         // 使用静态调度减少调度开销，块数足够多时static更高效
9         #pragma omp for schedule(static) collapse(3) nowait
10        for (int block_i = 1; block_i <= N; block_i += TILE_SIZE)
11        {
12            for (int block_j = 1; block_j <= N; block_j +=
13                TILE_SIZE) {
14                for (int block_k = 1; block_k <= N; block_k +=
15                    TILE_SIZE) {
```

```

13         int i_end = std::min(block_i + TILE_SIZE, N +
14             1);
15         int j_end = std::min(block_j + TILE_SIZE, N +
16             1);
17         int k_end = std::min(block_k + TILE_SIZE, N +
18             1);
19         // 在块内更新红点 - k循环直接跳2步
20         for (int i = block_i; i < i_end; ++i) {
21             for (int j = block_j; j < j_end; ++j) {
22                 // 计算k的起始值，确保(i+j+k)%2==0
23                 int k_start = block_k + ((i + j +
24                     block_k) % 2 == 0 ? 0 : 1);
25                 // k每次跳2，只访问红点，无需条件判断
26                 for (int k = k_start; k < k_end; k +=
27                     2) {
28                     // 寄存器缓存：减少内存访问
29                     double u_im = U(i-1, j, k);
30                     double u_ip = U(i+1, j, k);
31                     double u_jm = U(i, j-1, k);
32                     double u_jp = U(i, j+1, k);
33                     double u_km = U(i, j, k-1);
34                     double u_kp = U(i, j, k+1);
35                     double f_val = local_h2 * F(i-1,
36                         j-1, k-1);
37
38                     U(i, j, k) = local_inv6 * (u_im +
39                         u_ip + u_jm + u_jp + u_km +
40                         u_kp + f_val);
41                 }
42             }
43         }
44     }
45
46     #pragma omp barrier
47     //黑点更新同理，实现方法相同

```

B.4 三对角方程组求解实现

B.4.1 Sequential Thomas 算法

Code Listing 11: Sequential Thomas 算法实现

```
1  vector<double> thomas_solver(int n,
2                                const vector<double>& a,
3                                const vector<double>& b,
4                                const vector<double>& c,
5                                const vector<double>& d) {
6
7     vector<double> gamma(n, 0.0);
8     vector<double> rho(n, 0.0);
9
10    // 前向消元
11    gamma[0] = c[0] / b[0];
12    rho[0] = d[0] / b[0];
13
14    for (int i = 1; i < n; i++) {
15
16        double denom = b[i] - a[i] * gamma[i-1];
17
18        if (i < n - 1) {
19
20            gamma[i] = c[i] / denom;
21
22        }
23
24        rho[i] = (d[i] - a[i] * rho[i-1]) / denom;
25
26    }
27
28    // 回代
29    vector<double> x(n, 0.0);
30    x[n-1] = rho[n-1];
31
32    for (int i = n - 2; i >= 0; i--) {
33
34        x[i] = rho[i] - gamma[i] * x[i+1];
35
36    }
37
38    return x;
39}
```

B.4.2 Brugnano 并行算法

Code Listing 12: Brugnano 并行算法实现

```
1  void thomas_brugnano(int n,
2                        const vector<double>& global_a,
3                        const vector<double>& global_b,
4                        const vector<double>& global_c,
5                        const vector<double>& global_d,
6                        vector<double>& global_x,
```

```

7             int num_threads) {
8
9     vector<int> chunk_sizes(num_threads);
10    vector<int> start_indices(num_threads);
11    int base = n / num_threads;
12    int rem = n % num_threads;
13    int cur = 0;
14
15    for (int i = 0; i < num_threads; i++) {
16        chunk_sizes[i] = base + (i < rem ? 1 : 0);
17        start_indices[i] = cur;
18        cur += chunk_sizes[i];
19    }
20
21    vector<vector<double>> all_coefs(num_threads, vector<double>(6));
22    #pragma omp parallel num_threads(num_threads)
23    {
24
25        int tid = omp_get_thread_num();
26        int start_idx = start_indices[tid];
27        int m = chunk_sizes[tid];
28
29        vector<double> local_a(m), local_b(m), local_c(m), local_d(m)
30
31        ;
32
33        for (int i = 0; i < m; i++) {
34
35            int gi = start_idx + i;
36
37            local_a[i] = global_a[gi];
38            local_b[i] = global_b[gi];
39            local_c[i] = global_c[gi];
40            local_d[i] = global_d[gi];
41
42        }
43
44        if (m == 1) {
45
46            local_d[0] /= local_b[0];
47
48            local_a[0] = local_c[0] = 0.0;
49        } else {
50
51            modified_thomas_algorithm(m, local_a, local_b, local_c,
52
53                local_d);
54
55        }
56
57        all_coefs[tid][0] = local_a[0];
58        all_coefs[tid][1] = local_c[0];
59        all_coefs[tid][2] = local_d[0];
60        all_coefs[tid][3] = local_a[m-1];
61        all_coefs[tid][4] = local_c[m-1];
62        all_coefs[tid][5] = local_d[m-1];
63
64    }
65
66
```

```

45 #pragma omp barrier
46
47 #pragma omp single
48 {
49     int R = 2 * num_threads;
50     vector<double> ra(R, 0.0), rb(R, 1.0), rc(R, 0.0), rd(R);
51     for (int i = 0; i < num_threads; i++) {
52         int e1 = 2 * i;
53         int e2 = 2 * i + 1;
54         ra[e1] = all_coefs[i][0];
55         rc[e1] = all_coefs[i][1];
56         rd[e1] = all_coefs[i][2];
57         ra[e2] = all_coefs[i][3];
58         rc[e2] = all_coefs[i][4];
59         rd[e2] = all_coefs[i][5];
60     }
61     for (int i = 0; i < num_threads - 1; i++) {
62         int curr_end = 2 * i + 1;
63         int next_start = 2 * (i + 1);
64         rc[curr_end] = -ra[next_start];
65         ra[next_start] = -rc[curr_end];
66     }
67     standard_thomas_solver(R, ra, rb, rc, rd);
68     for (int i = 0; i < num_threads; i++) {
69         int s = start_indices[i];
70         int e = s + chunk_sizes[i] - 1;
71         global_x[s] = rd[2*i];
72         global_x[e] = rd[2*i+1];
73     }
74 }
75 #pragma omp barrier
76 int s = start_idx;
77 double d0 = global_x[s];
78 double dN = global_x[s + m - 1];
79
80 for (int i = 1; i < m - 1; i++) {
81     global_x[s + i] = local_d[i] - local_a[i] * d0 - local_c[
82         i] * dN;
83 }

```

B.4.3 Recursive Doubling 算法

Code Listing 13: Recursive Doubling 并行算法实现

```

1 void thomas_recursive_doubling(int n,
2                                 const vector<double>& a,
3                                 const vector<double>& b,
4                                 const vector<double>& c,
5                                 const vector<double>& q,
6                                 vector<double>& x,
7                                 int num_threads) {
8
9     vector<array<double, 4>> R_store(num_threads);
10    vector<double> d(n), l(n);
11
12 #pragma omp parallel num_threads(num_threads)
13 {
14
15     int tid = omp_get_thread_num();
16     int base = n / num_threads;
17     int rem = n % num_threads;
18     int local_rows = (tid < rem ? base + 1 : base);
19     int offset = (tid < rem ? tid * (base + 1) : rem * (base + 1)
20                   + (tid - rem) * base);
21
22     double R00 = 1.0, R01 = 0.0;
23     double R10 = 0.0, R11 = 1.0;
24
25     for (int i = 0; i < local_rows; i++) {
26
27         int idx = offset + i;
28
29         double a_val = a[idx];
30
31         double mult = (idx > 0 ? b[idx-1] * c[idx-1] : 0.0);
32
33
34         double tmp0 = a_val * R00 - mult * R10;
35         double tmp1 = a_val * R01 - mult * R11;
36
37         R10 = R00;
38         R11 = R01;
39         R00 = tmp0;
40         R01 = tmp1;
41
42
43         double scale = max({abs(R00), abs(R01), abs(R10), abs(R11
44                           )});
45
46         if (scale > 0) {
47
48             a_val = a_val / scale;
49
50             R00 = R00 / scale;
51             R01 = R01 / scale;
52             R10 = R10 / scale;
53             R11 = R11 / scale;
54
55             a[idx] = a_val;
56
57             if (idx > 0) {
58                 b[idx-1] = R01;
59                 c[idx-1] = R11;
60             }
61
62             if (idx < n - 1) {
63                 d[idx+1] = R10;
64                 l[idx+1] = R00;
65             }
66
67         }
68
69     }
70
71     x = l;
72
73     #pragma omp barrier
74
75     for (int i = 0; i < num_threads; i++) {
76
77         for (int j = 0; j < 4; j++) {
78             R_store[i][j] = R_store[i][j] / scale;
79         }
80     }
81
82     #pragma omp barrier
83
84     for (int i = 0; i < num_threads; i++) {
85
86         for (int j = 0; j < 4; j++) {
87             R_store[i][j] = R_store[i][j] * scale;
88         }
89     }
90
91     #pragma omp barrier
92
93     for (int i = 0; i < num_threads; i++) {
94
95         for (int j = 0; j < 4; j++) {
96             R_store[i][j] = R_store[i][j] / scale;
97         }
98     }
99
100    #pragma omp barrier
101
102    for (int i = 0; i < num_threads; i++) {
103
104        for (int j = 0; j < 4; j++) {
105            R_store[i][j] = R_store[i][j] * scale;
106        }
107    }
108
109    #pragma omp barrier
110
111    for (int i = 0; i < num_threads; i++) {
112
113        for (int j = 0; j < 4; j++) {
114            R_store[i][j] = R_store[i][j] / scale;
115        }
116    }
117
118    #pragma omp barrier
119
120    for (int i = 0; i < num_threads; i++) {
121
122        for (int j = 0; j < 4; j++) {
123            R_store[i][j] = R_store[i][j] * scale;
124        }
125    }
126
127    #pragma omp barrier
128
129    for (int i = 0; i < num_threads; i++) {
130
131        for (int j = 0; j < 4; j++) {
132            R_store[i][j] = R_store[i][j] / scale;
133        }
134    }
135
136    #pragma omp barrier
137
138    for (int i = 0; i < num_threads; i++) {
139
140        for (int j = 0; j < 4; j++) {
141            R_store[i][j] = R_store[i][j] * scale;
142        }
143    }
144
145    #pragma omp barrier
146
147    for (int i = 0; i < num_threads; i++) {
148
149        for (int j = 0; j < 4; j++) {
150            R_store[i][j] = R_store[i][j] / scale;
151        }
152    }
153
154    #pragma omp barrier
155
156    for (int i = 0; i < num_threads; i++) {
157
158        for (int j = 0; j < 4; j++) {
159            R_store[i][j] = R_store[i][j] * scale;
160        }
161    }
162
163    #pragma omp barrier
164
165    for (int i = 0; i < num_threads; i++) {
166
167        for (int j = 0; j < 4; j++) {
168            R_store[i][j] = R_store[i][j] / scale;
169        }
170    }
171
172    #pragma omp barrier
173
174    for (int i = 0; i < num_threads; i++) {
175
176        for (int j = 0; j < 4; j++) {
177            R_store[i][j] = R_store[i][j] * scale;
178        }
179    }
180
181    #pragma omp barrier
182
183    for (int i = 0; i < num_threads; i++) {
184
185        for (int j = 0; j < 4; j++) {
186            R_store[i][j] = R_store[i][j] / scale;
187        }
188    }
189
190    #pragma omp barrier
191
192    for (int i = 0; i < num_threads; i++) {
193
194        for (int j = 0; j < 4; j++) {
195            R_store[i][j] = R_store[i][j] * scale;
196        }
197    }
198
199    #pragma omp barrier
200
201    for (int i = 0; i < num_threads; i++) {
202
203        for (int j = 0; j < 4; j++) {
204            R_store[i][j] = R_store[i][j] / scale;
205        }
206    }
207
208    #pragma omp barrier
209
210    for (int i = 0; i < num_threads; i++) {
211
212        for (int j = 0; j < 4; j++) {
213            R_store[i][j] = R_store[i][j] * scale;
214        }
215    }
216
217    #pragma omp barrier
218
219    for (int i = 0; i < num_threads; i++) {
220
221        for (int j = 0; j < 4; j++) {
222            R_store[i][j] = R_store[i][j] / scale;
223        }
224    }
225
226    #pragma omp barrier
227
228    for (int i = 0; i < num_threads; i++) {
229
230        for (int j = 0; j < 4; j++) {
231            R_store[i][j] = R_store[i][j] * scale;
232        }
233    }
234
235    #pragma omp barrier
236
237    for (int i = 0; i < num_threads; i++) {
238
239        for (int j = 0; j < 4; j++) {
240            R_store[i][j] = R_store[i][j] / scale;
241        }
242    }
243
244    #pragma omp barrier
245
246    for (int i = 0; i < num_threads; i++) {
247
248        for (int j = 0; j < 4; j++) {
249            R_store[i][j] = R_store[i][j] * scale;
250        }
251    }
252
253    #pragma omp barrier
254
255    for (int i = 0; i < num_threads; i++) {
256
257        for (int j = 0; j < 4; j++) {
258            R_store[i][j] = R_store[i][j] / scale;
259        }
260    }
261
262    #pragma omp barrier
263
264    for (int i = 0; i < num_threads; i++) {
265
266        for (int j = 0; j < 4; j++) {
267            R_store[i][j] = R_store[i][j] * scale;
268        }
269    }
270
271    #pragma omp barrier
272
273    for (int i = 0; i < num_threads; i++) {
274
275        for (int j = 0; j < 4; j++) {
276            R_store[i][j] = R_store[i][j] / scale;
277        }
278    }
279
280    #pragma omp barrier
281
282    for (int i = 0; i < num_threads; i++) {
283
284        for (int j = 0; j < 4; j++) {
285            R_store[i][j] = R_store[i][j] * scale;
286        }
287    }
288
289    #pragma omp barrier
290
291    for (int i = 0; i < num_threads; i++) {
292
293        for (int j = 0; j < 4; j++) {
294            R_store[i][j] = R_store[i][j] / scale;
295        }
296    }
297
298    #pragma omp barrier
299
300    for (int i = 0; i < num_threads; i++) {
301
302        for (int j = 0; j < 4; j++) {
303            R_store[i][j] = R_store[i][j] * scale;
304        }
305    }
306
307    #pragma omp barrier
308
309    for (int i = 0; i < num_threads; i++) {
310
311        for (int j = 0; j < 4; j++) {
312            R_store[i][j] = R_store[i][j] / scale;
313        }
314    }
315
316    #pragma omp barrier
317
318    for (int i = 0; i < num_threads; i++) {
319
320        for (int j = 0; j < 4; j++) {
321            R_store[i][j] = R_store[i][j] * scale;
322        }
323    }
324
325    #pragma omp barrier
326
327    for (int i = 0; i < num_threads; i++) {
328
329        for (int j = 0; j < 4; j++) {
330            R_store[i][j] = R_store[i][j] / scale;
331        }
332    }
333
334    #pragma omp barrier
335
336    for (int i = 0; i < num_threads; i++) {
337
338        for (int j = 0; j < 4; j++) {
339            R_store[i][j] = R_store[i][j] * scale;
340        }
341    }
342
343    #pragma omp barrier
344
345    for (int i = 0; i < num_threads; i++) {
346
347        for (int j = 0; j < 4; j++) {
348            R_store[i][j] = R_store[i][j] / scale;
349        }
350    }
351
352    #pragma omp barrier
353
354    for (int i = 0; i < num_threads; i++) {
355
356        for (int j = 0; j < 4; j++) {
357            R_store[i][j] = R_store[i][j] * scale;
358        }
359    }
360
361    #pragma omp barrier
362
363    for (int i = 0; i < num_threads; i++) {
364
365        for (int j = 0; j < 4; j++) {
366            R_store[i][j] = R_store[i][j] / scale;
367        }
368    }
369
370    #pragma omp barrier
371
372    for (int i = 0; i < num_threads; i++) {
373
374        for (int j = 0; j < 4; j++) {
375            R_store[i][j] = R_store[i][j] * scale;
376        }
377    }
378
379    #pragma omp barrier
380
381    for (int i = 0; i < num_threads; i++) {
382
383        for (int j = 0; j < 4; j++) {
384            R_store[i][j] = R_store[i][j] / scale;
385        }
386    }
387
388    #pragma omp barrier
389
390    for (int i = 0; i < num_threads; i++) {
391
392        for (int j = 0; j < 4; j++) {
393            R_store[i][j] = R_store[i][j] * scale;
394        }
395    }
396
397    #pragma omp barrier
398
399    for (int i = 0; i < num_threads; i++) {
400
401        for (int j = 0; j < 4; j++) {
402            R_store[i][j] = R_store[i][j] / scale;
403        }
404    }
405
406    #pragma omp barrier
407
408    for (int i = 0; i < num_threads; i++) {
409
410        for (int j = 0; j < 4; j++) {
411            R_store[i][j] = R_store[i][j] * scale;
412        }
413    }
414
415    #pragma omp barrier
416
417    for (int i = 0; i < num_threads; i++) {
418
419        for (int j = 0; j < 4; j++) {
420            R_store[i][j] = R_store[i][j] / scale;
421        }
422    }
423
424    #pragma omp barrier
425
426    for (int i = 0; i < num_threads; i++) {
427
428        for (int j = 0; j < 4; j++) {
429            R_store[i][j] = R_store[i][j] * scale;
430        }
431    }
432
433    #pragma omp barrier
434
435    for (int i = 0; i < num_threads; i++) {
436
437        for (int j = 0; j < 4; j++) {
438            R_store[i][j] = R_store[i][j] / scale;
439        }
440    }
441
442    #pragma omp barrier
443
444    for (int i = 0; i < num_threads; i++) {
445
446        for (int j = 0; j < 4; j++) {
447            R_store[i][j] = R_store[i][j] * scale;
448        }
449    }
450
451    #pragma omp barrier
452
453    for (int i = 0; i < num_threads; i++) {
454
455        for (int j = 0; j < 4; j++) {
456            R_store[i][j] = R_store[i][j] / scale;
457        }
458    }
459
460    #pragma omp barrier
461
462    for (int i = 0; i < num_threads; i++) {
463
464        for (int j = 0; j < 4; j++) {
465            R_store[i][j] = R_store[i][j] * scale;
466        }
467    }
468
469    #pragma omp barrier
470
471    for (int i = 0; i < num_threads; i++) {
472
473        for (int j = 0; j < 4; j++) {
474            R_store[i][j] = R_store[i][j] / scale;
475        }
476    }
477
478    #pragma omp barrier
479
480    for (int i = 0; i < num_threads; i++) {
481
482        for (int j = 0; j < 4; j++) {
483            R_store[i][j] = R_store[i][j] * scale;
484        }
485    }
486
487    #pragma omp barrier
488
489    for (int i = 0; i < num_threads; i++) {
490
491        for (int j = 0; j < 4; j++) {
492            R_store[i][j] = R_store[i][j] / scale;
493        }
494    }
495
496    #pragma omp barrier
497
498    for (int i = 0; i < num_threads; i++) {
499
500        for (int j = 0; j < 4; j++) {
501            R_store[i][j] = R_store[i][j] * scale;
502        }
503    }
504
505    #pragma omp barrier
506
507    for (int i = 0; i < num_threads; i++) {
508
509        for (int j = 0; j < 4; j++) {
510            R_store[i][j] = R_store[i][j] / scale;
511        }
512    }
513
514    #pragma omp barrier
515
516    for (int i = 0; i < num_threads; i++) {
517
518        for (int j = 0; j < 4; j++) {
519            R_store[i][j] = R_store[i][j] * scale;
520        }
521    }
522
523    #pragma omp barrier
524
525    for (int i = 0; i < num_threads; i++) {
526
527        for (int j = 0; j < 4; j++) {
528            R_store[i][j] = R_store[i][j] / scale;
529        }
530    }
531
532    #pragma omp barrier
533
534    for (int i = 0; i < num_threads; i++) {
535
536        for (int j = 0; j < 4; j++) {
537            R_store[i][j] = R_store[i][j] * scale;
538        }
539    }
540
541    #pragma omp barrier
542
543    for (int i = 0; i < num_threads; i++) {
544
545        for (int j = 0; j < 4; j++) {
546            R_store[i][j] = R_store[i][j] / scale;
547        }
548    }
549
550    #pragma omp barrier
551
552    for (int i = 0; i < num_threads; i++) {
553
554        for (int j = 0; j < 4; j++) {
555            R_store[i][j] = R_store[i][j] * scale;
556        }
557    }
558
559    #pragma omp barrier
560
561    for (int i = 0; i < num_threads; i++) {
562
563        for (int j = 0; j < 4; j++) {
564            R_store[i][j] = R_store[i][j] / scale;
565        }
566    }
567
568    #pragma omp barrier
569
570    for (int i = 0; i < num_threads; i++) {
571
572        for (int j = 0; j < 4; j++) {
573            R_store[i][j] = R_store[i][j] * scale;
574        }
575    }
576
577    #pragma omp barrier
578
579    for (int i = 0; i < num_threads; i++) {
580
581        for (int j = 0; j < 4; j++) {
582            R_store[i][j] = R_store[i][j] / scale;
583        }
584    }
585
586    #pragma omp barrier
587
588    for (int i = 0; i < num_threads; i++) {
589
590        for (int j = 0; j < 4; j++) {
591            R_store[i][j] = R_store[i][j] * scale;
592        }
593    }
594
595    #pragma omp barrier
596
597    for (int i = 0; i < num_threads; i++) {
598
599        for (int j = 0; j < 4; j++) {
600            R_store[i][j] = R_store[i][j] / scale;
601        }
602    }
603
604    #pragma omp barrier
605
606    for (int i = 0; i < num_threads; i++) {
607
608        for (int j = 0; j < 4; j++) {
609            R_store[i][j] = R_store[i][j] * scale;
610        }
611    }
612
613    #pragma omp barrier
614
615    for (int i = 0; i < num_threads; i++) {
616
617        for (int j = 0; j < 4; j++) {
618            R_store[i][j] = R_store[i][j] / scale;
619        }
620    }
621
622    #pragma omp barrier
623
624    for (int i = 0; i < num_threads; i++) {
625
626        for (int j = 0; j < 4; j++) {
627            R_store[i][j] = R_store[i][j] * scale;
628        }
629    }
630
631    #pragma omp barrier
632
633    for (int i = 0; i < num_threads; i++) {
634
635        for (int j = 0; j < 4; j++) {
636            R_store[i][j] = R_store[i][j] / scale;
637        }
638    }
639
640    #pragma omp barrier
641
642    for (int i = 0; i < num_threads; i++) {
643
644        for (int j = 0; j < 4; j++) {
645            R_store[i][j] = R_store[i][j] * scale;
646        }
647    }
648
649    #pragma omp barrier
650
651    for (int i = 0; i < num_threads; i++) {
652
653        for (int j = 0; j < 4; j++) {
654            R_store[i][j] = R_store[i][j] / scale;
655        }
656    }
657
658    #pragma omp barrier
659
660    for (int i = 0; i < num_threads; i++) {
661
662        for (int j = 0; j < 4; j++) {
663            R_store[i][j] = R_store[i][j] * scale;
664        }
665    }
666
667    #pragma omp barrier
668
669    for (int i = 0; i < num_threads; i++) {
670
671        for (int j = 0; j < 4; j++) {
672            R_store[i][j] = R_store[i][j] / scale;
673        }
674    }
675
676    #pragma omp barrier
677
678    for (int i = 0; i < num_threads; i++) {
679
680        for (int j = 0; j < 4; j++) {
681            R_store[i][j] = R_store[i][j] * scale;
682        }
683    }
684
685    #pragma omp barrier
686
687    for (int i = 0; i < num_threads; i++) {
688
689        for (int j = 0; j < 4; j++) {
690            R_store[i][j] = R_store[i][j] / scale;
691        }
692    }
693
694    #pragma omp barrier
695
696    for (int i = 0; i < num_threads; i++) {
697
698        for (int j = 0; j < 4; j++) {
699            R_store[i][j] = R_store[i][j] * scale;
700        }
701    }
702
703    #pragma omp barrier
704
705    for (int i = 0; i < num_threads; i++) {
706
707        for (int j = 0; j < 4; j++) {
708            R_store[i][j] = R_store[i][j] / scale;
709        }
710    }
711
712    #pragma omp barrier
713
714    for (int i = 0; i < num_threads; i++) {
715
716        for (int j = 0; j < 4; j++) {
717            R_store[i][j] = R_store[i][j] * scale;
718        }
719    }
720
721    #pragma omp barrier
722
723    for (int i = 0; i < num_threads; i++) {
724
725        for (int j = 0; j < 4; j++) {
726            R_store[i][j] = R_store[i][j] / scale;
727        }
728    }
729
730    #pragma omp barrier
731
732    for (int i = 0; i < num_threads; i++) {
733
734        for (int j = 0; j < 4; j++) {
735            R_store[i][j] = R_store[i][j] * scale;
736        }
737    }
738
739    #pragma omp barrier
740
741    for (int i = 0; i < num_threads; i++) {
742
743        for (int j = 0; j < 4; j++) {
744            R_store[i][j] = R_store[i][j] / scale;
745        }
746    }
747
748    #pragma omp barrier
749
750    for (int i = 0; i < num_threads; i++) {
751
752        for (int j = 0; j < 4; j++) {
753            R_store[i][j] = R_store[i][j] * scale;
754        }
755    }
756
757    #pragma omp barrier
758
759    for (int i = 0; i < num_threads; i++) {
760
761        for (int j = 0; j < 4; j++) {
762            R_store[i][j] = R_store[i][j] / scale;
763        }
764    }
765
766    #pragma omp barrier
767
768    for (int i = 0; i < num_threads; i++) {
769
770        for (int j = 0; j < 4; j++) {
771            R_store[i][j] = R_store[i][j] * scale;
772        }
773    }
774
775    #pragma omp barrier
776
777    for (int i = 0; i < num_threads; i++) {
778
779        for (int j = 0; j < 4; j++) {
780            R_store[i][j] = R_store[i][j] / scale;
781        }
782    }
783
784    #pragma omp barrier
785
786    for (int i = 0; i < num_threads; i++) {
787
788        for (int j = 0; j < 4; j++) {
789            R_store[i][j] = R_store[i][j] * scale;
790        }
791    }
792
793    #pragma omp barrier
794
795    for (int i = 0; i < num_threads; i++) {
796
797        for (int j = 0; j < 4; j++) {
798            R_store[i][j] = R_store[i][j] / scale;
799        }
800    }
801
802    #pragma omp barrier
803
804    for (int i = 0; i < num_threads; i++) {
805
806        for (int j = 0; j < 4; j++) {
807            R_store[i][j] = R_store[i][j] * scale;
808        }
809    }
810
811    #pragma omp barrier
812
813    for (int i = 0; i < num_threads; i++) {
814
815        for (int j = 0; j < 4; j++) {
816            R_store[i][j] = R_store[i][j] / scale;
817        }
818    }
819
820    #pragma omp barrier
821
822    for (int i = 0; i < num_threads; i++) {
823
824        for (int j = 0; j < 4; j++) {
825            R_store[i][j] = R_store[i][j] * scale;
826        }
827    }
828
829    #pragma omp barrier
830
831    for (int i = 0; i < num_threads; i++) {
832
833        for (int j = 0; j < 4; j++) {
834            R_store[i][j] = R_store[i][j] / scale;
835        }
836    }
837
838    #pragma omp barrier
839
840    for (int i = 0; i < num_threads; i++) {
841
842        for (int j = 0; j < 4; j++) {
843            R_store[i][j] = R_store[i][j] * scale;
844        }
845    }
846
847    #pragma omp barrier
848
849    for (int i = 0; i < num_threads; i++) {
850
851        for (int j = 0; j < 4; j++) {
852            R_store[i][j] = R_store[i][j] / scale;
853        }
854    }
855
856    #pragma omp barrier
857
858    for (int i = 0; i < num_threads; i++) {
859
860        for (int j = 0; j < 4; j++) {
861            R_store[i][j] = R_store[i][j] * scale;
862        }
863    }
864
865    #pragma omp barrier
866
867    for (int i = 0; i < num_threads; i++) {
868
869        for (int j = 0; j < 4; j++) {
870            R_store[i][j] = R_store[i][j] / scale;
871        }
872    }
873
874    #pragma omp barrier
875
876    for (int i = 0; i < num_threads; i++) {
877
878        for (int j = 0; j < 4; j++) {
879            R_store[i][j] = R_store[i][j] * scale;
880        }
881    }
882
883    #pragma omp barrier
884
885    for (int i = 0; i < num_threads; i++) {
886
887        for (int j = 0; j < 4; j++) {
888            R_store[i][j] = R_store[i][j] / scale;
889        }
890    }
891
892    #pragma omp barrier
893
894    for (int i = 0; i < num_threads; i++) {
895
896        for (int j = 0; j < 4; j++) {
897            R_store[i][j] = R_store[i][j] * scale;
898        }
899    }
900
901    #pragma omp barrier
902
903    for (int i = 0; i < num_threads; i++) {
904
905        for (int j = 0; j < 4; j++) {
906            R_store[i][j] = R_store[i][j] / scale;
907        }
908    }
909
910    #pragma omp barrier
911
912    for (int i = 0; i < num_threads; i++) {
913
914        for (int j = 0; j < 4; j++) {
915            R_store[i][j] = R_store[i][j] * scale;
916        }
917    }
918
919    #pragma omp barrier
920
921    for (int i = 0; i < num_threads; i++) {
922
923        for (int j = 0; j < 4; j++) {
924            R_store[i][j] = R_store[i][j] / scale;
925        }
926    }
927
928    #pragma omp barrier
929
930    for (int i = 0; i < num_threads; i++) {
931
932        for (int j = 0; j < 4; j++) {
933            R_store[i][j] = R_store[i][j] * scale;
934        }
935    }
936
937    #pragma omp barrier
938
939    for (int i = 0; i < num_threads; i++) {
940
941        for (int j = 0; j < 4; j++) {
942            R_store[i][j] = R_store[i][j] / scale;
943        }
944    }
945
946    #pragma omp barrier
947
948    for (int i = 0; i < num_threads; i++) {
949
950        for (int j = 0; j < 4; j++) {
951            R_store[i][j] = R_store[i][j] * scale;
952        }
953    }
954
955    #pragma omp barrier
956
957    for (int i = 0; i < num_threads; i++) {
958
959        for (int j = 0; j < 4; j++) {
960            R_store[i][j] = R_store[i][j] / scale;
961        }
962    }
963
964    #pragma omp barrier
965
966    for (int i = 0; i < num_threads; i++) {
967
968        for (int j = 0; j < 4; j++) {
969            R_store[i][j] = R_store[i][j] * scale;
970        }
971    }
972
973    #pragma omp barrier
974
975    for (int i = 0; i < num_threads; i++) {
976
977        for (int j = 0; j < 4; j++) {
978            R_store[i][j] = R_store[i][j] / scale;
979        }
980    }
981
982    #pragma omp barrier
983
984    for (int i = 0; i < num_threads; i++) {
985
986        for (int j = 0; j < 4; j++) {
987            R_store[i][j] = R_store[i][j] * scale;
988        }
989    }
990
991    #pragma omp barrier
992
993    for (int i = 0; i < num_threads; i++) {
994
995        for (int j = 0; j < 4; j++) {
996            R_store[i][j] = R_store[i][j] / scale;
997        }
998    }
999
1000   #pragma omp barrier
1001
1002   for (int i = 0; i < num_threads; i++) {
1003
1004       for (int j = 0; j < 4; j++) {
1005           R_store[i][j] = R_store[i][j] * scale;
1006       }
1007   }
1008
1009   #pragma omp barrier
1010
1011   for (int i = 0; i < num_threads; i++) {
1012
1013       for (int j = 0; j < 4; j++) {
1014           R_store[i][j] = R_store[i][j] / scale;
1015       }
1016   }
1017
1018   #pragma omp barrier
1019
1020   for (int i = 0; i < num_threads; i++) {
1021
1022       for (int j = 0; j < 4; j++) {
1023           R_store[i][j] = R_store[i][j] * scale;
1024       }
1025   }
1026
1027   #pragma omp barrier
1028
1029   for (int i = 0; i < num_threads; i++) {
1030
1031       for (int j = 0; j < 4; j++) {
1032           R_store[i][j] = R_store[i][j] / scale;
1033       }
1034   }
1035
1036   #pragma omp barrier
1037
1038   for (int i = 0; i < num_threads; i++) {
1039
1040       for (int j = 0; j < 4; j++) {
1041           R_store[i][j] = R_store[i][j] * scale;
1042       }
1043   }
1044
1045   #pragma omp barrier
1046
1047   for (int i = 0; i < num_threads; i++) {

```

```

33         R00 /= scale; R01 /= scale;
34         R10 /= scale; R11 /= scale;
35     }
36 }
37 R_store[tid] = {R00, R01, R10, R11};
38 #pragma omp barrier
39 int stages = (int)log2(num_threads);
40 for (int s = 0; s < stages; s++) {
41     int dist = 1 << s;
42     auto my_R = R_store[tid];
43     int partner = (tid >= dist ? tid - dist : tid + dist);
44     auto p_R = R_store[partner];
45
46     double n00 = my_R[0] * p_R[0] + my_R[1] * p_R[2];
47     double n01 = my_R[0] * p_R[1] + my_R[1] * p_R[3];
48     double n10 = my_R[2] * p_R[0] + my_R[3] * p_R[2];
49     double n11 = my_R[2] * p_R[1] + my_R[3] * p_R[3];
50
51     double scale = max({abs(n00), abs(n01), abs(n10), abs(n11
52         )});
53     if (scale > 0) {
54         n00 /= scale; n01 /= scale;
55         n10 /= scale; n11 /= scale;
56     }
57
58     R_store[tid] = {n00, n01, n10, n11};
59     #pragma omp barrier
60 }
61 double p_sum = 0.0, q_sum = 0.0;
62 for (int i = 0; i < local_rows; i++) {
63     int idx = offset + i;
64     p_sum += b[idx];
65     q_sum += b[idx] * q[idx];
66 }
67 d[tid] = p_sum;
68 l[tid] = q_sum;
69 #pragma omp barrier
70 for (int s = 0; s < stages; s++) {
71     int dist = 1 << s;
72     if (tid >= dist) {

```

```
72     int partner = tid - dist;
73     d[tid] += d[partner];
74     l[tid] += l[partner];
75   }
76   #pragma omp barrier
77 }
78 for (int i = 0; i < local_rows; i++) {
79   int idx = offset + i;
80   x[idx] = (q[idx] - (idx > 0 ? c[idx-1] * x[idx-1] : 0.0))
81   / b[idx];
82 }
83 }
```

C 写在最后

C.1 发布地址

本项目的完整代码和文档均已开源，欢迎访问 Github 仓库获取最新版本：

- Github: https://github.com/watney1024/iteration_final_project